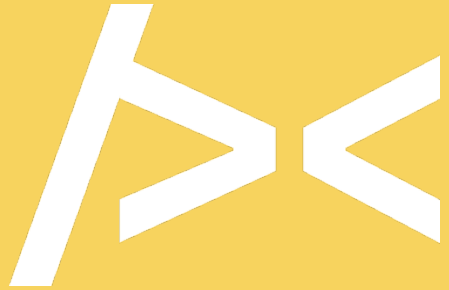
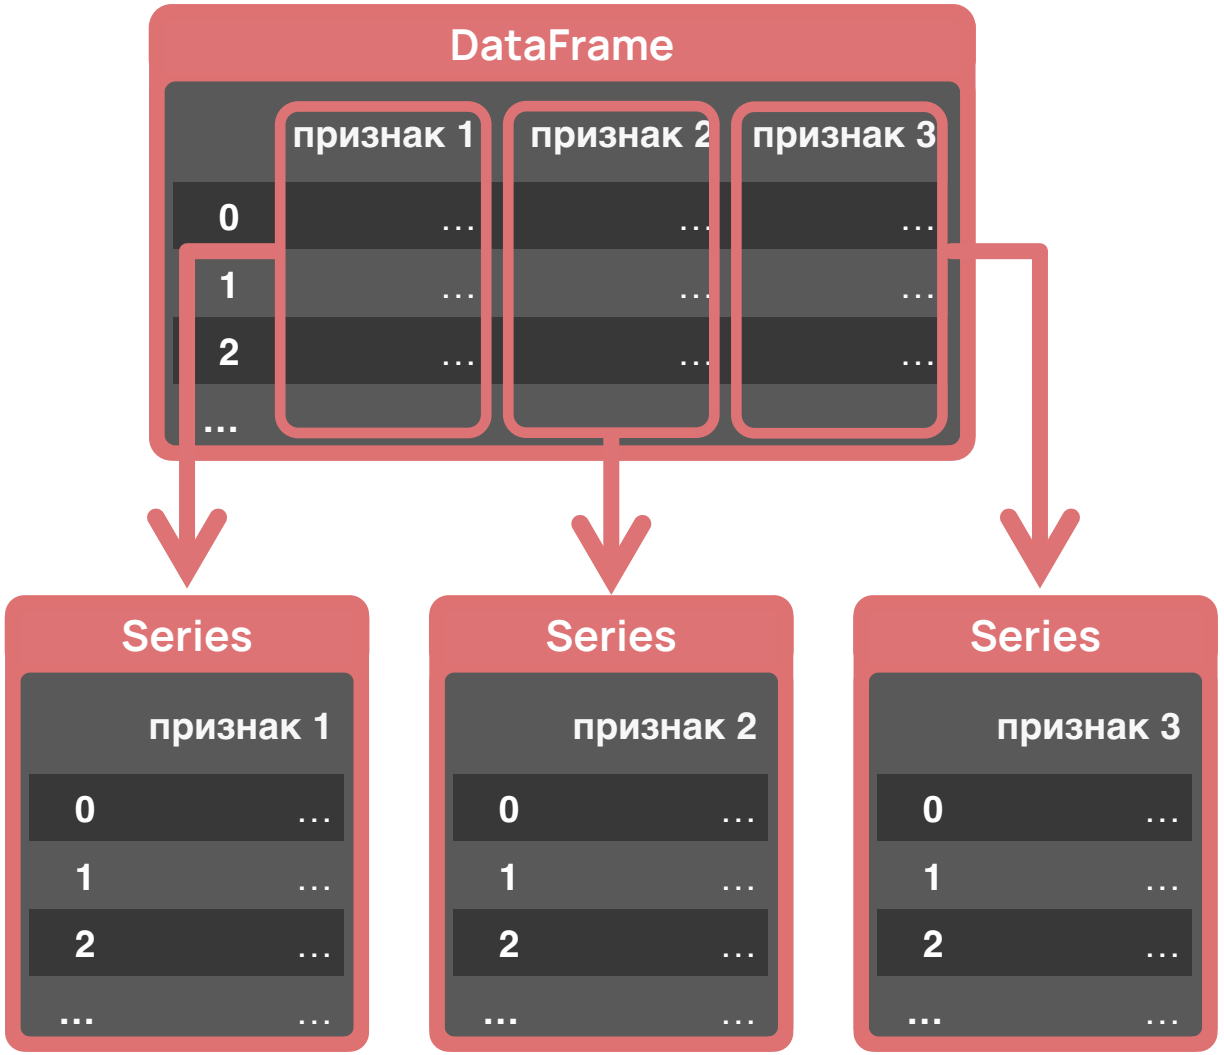
БИБЛИОТЕКА PANDAS



СТРУКТУРЫ ДАННЫХ В PANDAS



DataFrame – таблица, в которой есть индекс и признак(и).

Каждый отдельный признак датафрейма имеет формат **Series.**

Series – таблица, в которой есть индекс и только один признак.

ОТКРЫТИЕ ФАЙЛА В PANDAS

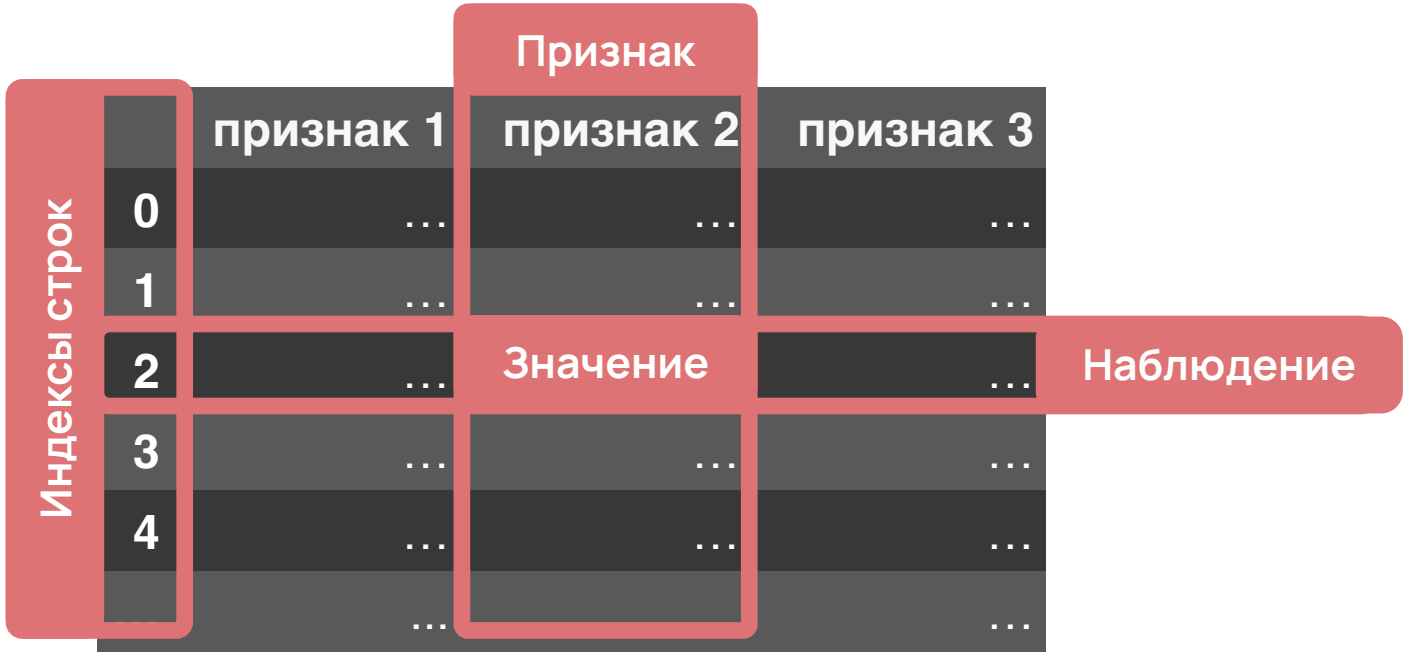
```
import pandas as pd
df = pd.read_csv('путь/country_e.csv')
df.head()
```

	country	GDP	neighbors	is_landlocked	co2_total
0	Malta	25.29	0	False	small
1	Romania	382.77	5	False	small
2	Slovakia	154.59	5	True	medium
3	Norway	485.66	3	False	high
4	Belgium	889.83	4	False	medium

country – название страны
GDP – ВВП (млрд. долларов)
neighbors – количество сухопутных границ
Is_landlocked – отсутствие выхода к морю
co2_total – уровень выбросов CO2

ЗАЧЕМ ДОБАВЛЯЕМ `as pd`, ПРИ ИМПОРТЕ БИБЛИОТЕКИ?
МОЖНО ЛИ ОТКРЫТЬ ЭКСЕЛЬ ФАЙЛ, С ПОМОЩЬЮ PANDAS?
ЧТО ДЕЛАЕТ МЕТОД `.head()`?

ОБРАЩЕНИЕ К ЭЛЕМЕНТАМ ДАТАФРЕЙМА



Индексы строк

```
датафрейм.index
```

Признак

```
датафрейм['признак']
```

Наблюдение

```
датафрейм.loc[индекс]
```

Значение

```
датафрейм.loc[индекс]['признак']
```

ОСНОВНАЯ ИНФОРМАЦИЯ ПРО ДАТАФРЕЙМ

РАЗМЕР ДАТАФРЕЙМА

```
df.shape
```

```
(50, 5)
```

ФОРМАТ ДАННЫХ

```
df.dtypes
```

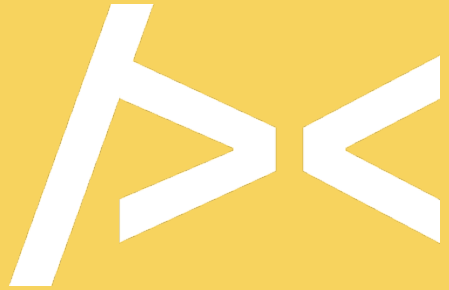
	0
country	object
GDP	float64
neighbors	int64
is_landlocked	bool
co2_total	object

КАКОЙ ТИП ДАННЫХ ВОЗВРАЩАЕТ `.shape`?

КАК ИЗВЛЕЧЬ КОЛИЧЕСТВО СТРОК?

ЧТО СКРЫВАЕТСЯ, ПОД КАЖДЫМ ФОРМАТОМ?

ФОРМАТ DATETIME



РАБОТА С ПРИЗНАКОМ ДАТЫ И ВРЕМЕНИ

```
df['DateTime']= pd.to_datetime(df['DateTime'])
```

```
датафрейм['новый признак'] = датафрейм['признак'].dt.компонент
```

df

	DateTime	year	month	day	hour	minute	second	DayName	DayOfWeek	week
0	2023-10-28 00:57:35	2023	10	28	0	57	35	Saturday	5	43
1	1999-12-31 12:45:23	1999	12	31	12	45	23	Friday	4	52
2	2026-02-15 09:29:00	2026	2	15	9	29	0	Sunday	6	7
3	2005-05-22 10:12:59	2005	5	22	10	12	59	Sunday	6	20
4	2006-11-02 23:11:06	2006	11	2	23	11	6	Thursday	3	44

КАКИЕ КОМПОНЕНТЫ БЫЛИ ИСПОЛЬЗОВАНЫ?

ШКАЛЫ ПРИЗНАКОВ

ПРИЗНАКИ В АНАЛИЗЕ ДАННЫХ

КОЛИЧЕСТВЕННЫЕ ПРИЗНАКИ

Измеряют числено наблюдение

ДИСКРЕТНЫЕ

Могут принимать только целые числа. Пример: количество стран

НЕПРЕРЫВНЫЕ

Могут принимать нецелые числа.
Пример: ВВП стран (млрд. долларов)

КАТЕГОРИАЛЬНЫЕ ПРИЗНАКИ

Определяют наблюдение в определенную группу

ПОРЯДКОВЫЕ

Категории имеют иерархию.
Пример: ВВП стран (высокий/средний/низкий)

НОМИНАЛЬНЫЕ

Категории равнозначны.
Пример: Регион (Европа/Азия/Африка/...)

БИНАРНЫЕ

Только две категории.
Пример: Входит ли страна в БРИКС?

A1

Определите шкалы измерения признака:

- Уровень дохода пользователя (низкий / средний / высокий)
- Цвет выбранного товара (красный, зеленый, синий)
- Совершил ли пользователь покупку (1 — да, 0 — нет)
- Общее время, проведенное пользователем на сайте (в минутах)
- Количество товаров, добавленных в корзину

- Плотность лавы по шкале от 1 до 10
- Название горной породы, образующей вулкан
- Температура в жерле в градусах Цельсия
- Наличие поселений у подножья вулкана
- Количество извержений за последние 10 лет

- Количество посадочных мест
- Факт страховки машины
- Расход топлива
- Класс качества машины
- Цвет автомобиля

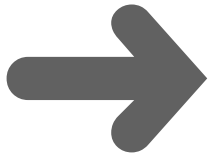
СОРТИРОВКА ДАННЫХ

СОРТИРОВКА ДАТАФРЕЙМА

ПО ВОЗРАСТАНИЮ

```
df.sort_values('val')
```

	name	val
0	C	15
1	B	5
2	A	10
3	B	20

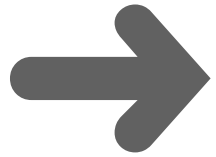


	name	val
1	B	5
2	A	10
0	C	15
3	B	20

ПО УБЫВАНИЮ

```
df.sort_values('val', ascending=False)
```

	name	val
0	C	15
1	B	5
2	A	10
3	B	20



	name	val
3	B	20
0	C	15
2	A	10
1	B	5

КАК БУДЕТ ВЫГЛЯДЕТЬ ДАТАФРЕЙМ ПРИ ТАКИХ СОРТИРОВКАХ?

```
df.sort_values(['name', 'val'])
```

```
df.sort_values(['name', 'val'], ascending=False)
```

```
df.sort_values(['name', 'val'], ascending=[True, False])
```

РАЗНИЦА МЕЖДУ .LOC И .ILOC

Нужно Вернуть имя (**name**) наблюдения с наименьшим значением (**val**). Какой из вариантов будет правильным?

	name	val
0	C	15
1	B	5
2	A	10
3	B	20

```
df.sort_values('val').loc[0]['name']
```

```
'C'
```

```
df.sort_values('val').iloc[0]['name']
```

```
'B'
```

МЕТОД .LOC

- Обращается к наблюдению по **индексу**
- **Индекс не меняется** при сортировке

МЕТОД .ILOC

- Обращается к наблюдению по **положению**
- **Положение меняется** при сортировке
- Первая строка имеет положение **0**, последняя строка имеет индекс **-1**

КЕЙС

КЕЙС

Исследователь изучает ВВП (**gdp**) стран мира (**country**). Укажите, что вернет код в каждом случае .

A
```
df.sort_values('gdp', ascending=False).loc[-1]['country']
```

B
```
df.sort_values('gdp', ascending=False).iloc[0]['country']
```

C
```
df.sort_values('gdp', ascending=False).iloc[-1]['country']
```

D
```
df.sort_values('gdp', ascending=False).loc[0]['country']
```

I Название страны с самым маленьким ВВП

II Название страны с самым большим ВВП

III Название страны под индексом 0

IV Ошибка

	country	gdp
0	Malta	25.29
1	Romania	382.77
2	Slovakia	154.59
...	...	...

ФИЛЬТРАЦИЯ ДАННЫХ

ФИЛЬТРАЦИЯ С ОДНИМ УСЛОВИЕМ

```
датафрейм[условие]
```

КЕЙС

Исследователь хочет найти все страны с низким уровнем выбросов CO2 (small; **co2_total**).

```
df[df['co2_total'] == 'small']
```

	country	GDP	neighbors	is_landlocked	co2_total
0	Malta	25.29	0	False	small
1	Romania	382.77	5	False	small
34	France	3162.08	8	False	small
40	Latvia	43.52	4	False	small
...	...	...	...	...	...

ПОЧЕМУ ДВА РАЗА `df`?

КАК ПОСЧИТАТЬ КОЛИЧЕСТВО СТРАН?

ФИЛЬТРАЦИЯ ПО НЕСКОЛЬКИМ УСЛОВИЯМ (1)

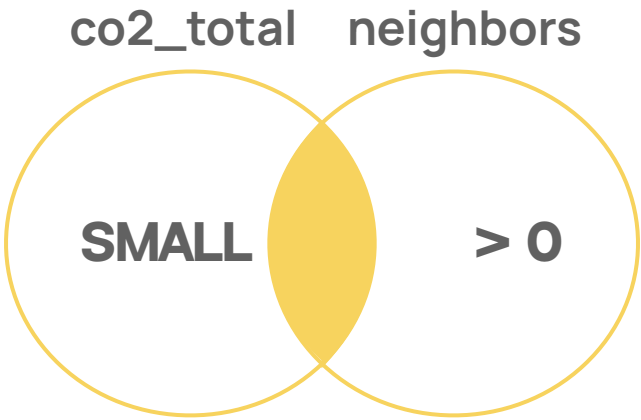
```
датафрейм[(условие 1) оператор (условие 2)оператор …]
```

КЕЙС

Исследователь хочет найти все странны с низким уровнем выбросов CO2 (small; **co2_total**), которые имеют сухопутных соседей (0; **neighbors**).

```
df[(df['co2_total'] == 'small') & (df['neighbors'] > 0)]
```

	country	GDP	neighbors	is_landlocked	co2_total
1	Romania	382.77	5	False	small
34	France	3162.08	8	False	small
40	Latvia	43.52	4	False	small
…	…	…	…	…	…



ФИЛЬТРАЦИЯ ПО НЕСКОЛЬКИМ УСЛОВИЯМ (2)

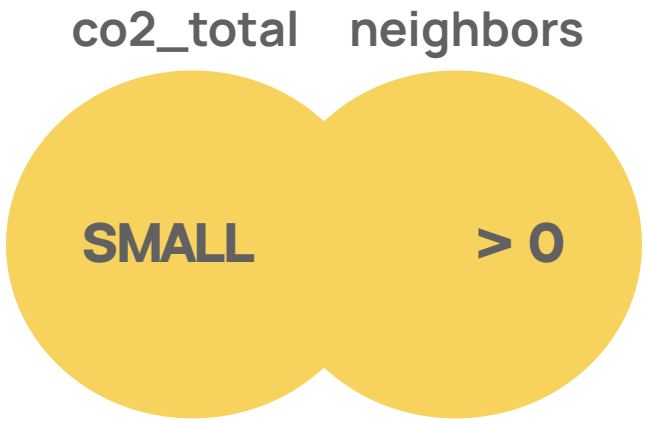
```
датафрейм[(условие 1) оператор (условие 2)оператор …]
```

КЕЙС

Исследователь хочет найти либо страны с низким уровнем выбросов CO2 (small; **co2_total**), либо те, которые имеют сухопутных соседей (0; **neighbors**).

```
df[(df['co2_total'] == 'small') | (df['neighbors'] > 0)]
```

	country	GDP	neighbors	is_landlocked	co2_total
0	Malta	25.29	0	False	small
1	Romania	382.77	5	False	small
2	Slovakia	154.59	5	True	medium
3	Norway	485.66	3	False	high
...	...	...	...	...	...



ФИЛЬТРАЦИЯ ПО НЕСКОЛЬКИМ УСЛОВИЯМ (3)

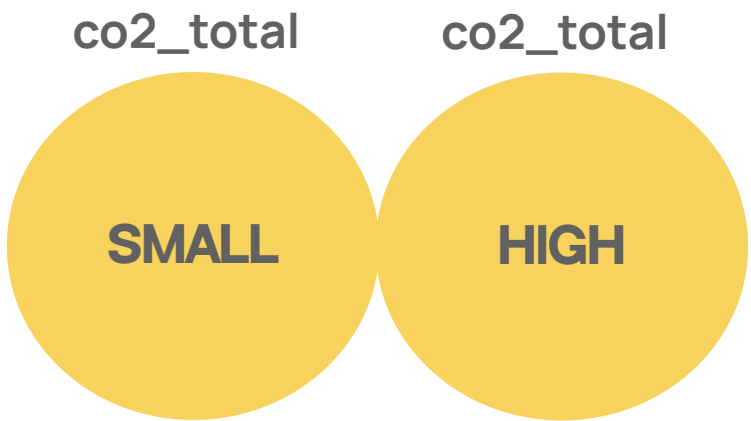
```
датафрейм[датафрейм['признак'].isin([объект 1, объект 2, …])]
```

КЕЙС

Исследователь хочет найти страны с низким (small; **co2_total**) и высоким (high; **co2_total**) уровнем выбросов CO2.

```
df[df['co2_total'].isin(['small', 'high'])]
```

	country	GDP	neighbors	is_landlocked	co2_total
0	Malta	25.29	0	False	small
1	Romania	382.77	5	False	small
3	Norway	485.66	3	False	high
15	Germany	4591.43	9	False	high
...	...	...	...	...	...



ФИЛЬТРАЦИЯ ПО НЕСКОЛЬКИМ УСЛОВИЯМ (4)

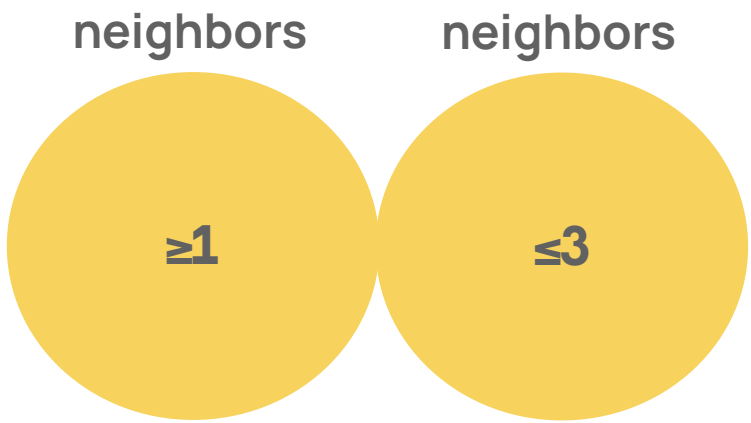
```
датафрейм[датафрейм['признак'].between(начало, конец)]
```

КЕЙС

Исследователь хочет найти страны у которых от 1 до 3 соседей (**neighbors**).

```
df[df['neighbors'].between(1, 3)]
```

	country	GDP	neighbors	is_landlocked	co2_total
3	Norway	485.66	3	False	high
6	Portugal	287.63	1	False	medium
12	Denmark	420.61	1	False	small
27	Andorra	3.69	2	True	high
...	...	...	...	...	...



ФИЛЬТРАЦИЯ И СОРТИРОВКА

```
датафрейм[условие].sort_values(признак, …)
```

КЕЙС

Среди страны у которых от 1 до 3 соседей (**neighbors**), нужно найти страну (**country**) с наименьшим значением ВВП (**GDP**).

Фильтрация	Сортировка	Результат

```
df[df['neighbors'].between(1, 3)].sort_values('GDP').iloc[0]['country']
```

```
'Vatican'
```

НОВЫЕ ПРИЗНАКИ

АРИФМЕТИЧЕСКИЕ ОПЕРАЦИИ

КЕЙС

Нужно создать новый признак **GDP_per_cap**, который будет представлять из себя ВВП на душу населения (**GDP**/**pop***1000).

```
df['GDP_per_cap'] = df['GDP']/df['pop']*1000
```

	country	GDP	pop	GDP_per_cap
0	Malta	25.29	0.45	56200.00
1	Romania	382.77	18.40	20802.72
2	Slovakia	154.59	5.48	28209.85
3	Norway	485.66	5.59	86880.14
4	Belgium	889.83	12.03	73967.58
...	...	...	...	...

АНОНИМНАЯ ФУНКЦИЯ

```
датафрейм['новый признак'] = датафрейм['признак'].apply(lambda x: <инструкция>)
```

КЕЙС

Создайте новый признак **neighbors**, на основе признака **n_ neighbors**, который будет подсчитывать количество сухопутных соседей у каждой страны. Известно, что страны в **n_ neighbors** перечислены через запятую.

```
df['neighbors'] = df['n_neighbors'].apply(lambda x: 0 if pd.isna(x) else x.count(',')+1)
```

	country	n_neighbors	neighbors
0	Malta	NaN	0
1	Romania	Ukraine,Moldova,Bul…	5
2	Slovakia	Poland, Ukraine,Hun…	5
3	Norway	Finland,Russia,Swe…	3
...	…	…	…

ИМЕНОВАННАЯ ФУНКЦИЯ

СОЗДАНИЕ

```
def название функции(x):
  <инструкция>
  return <результат>
```

ПРИМЕНЕНИЕ

```
датафрейм['новый признак'] = датафрейм['признак'].apply(название функции)
```

КЕЙС

Создайте новый признак **neighbors**, на основе признака **n_ neighbors**, который будет подсчитывать количество сухопутных соседей у каждой страны. Известно, что страны в **n_ neighbors** перечислены через запятую. Если сухопутных соседей нет, то NaN.

```
def recoded(x):
  if x.isna():
    return 0
  else:
    return x.count(',')+1

df['neighbors'] = df['n_neighbors'].apply(recoded)
```

КОДИРОВАНИЕ ДАННЫХ

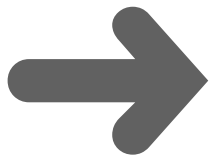
ONE-HOT КОДИРОВАНИЕ

```
pd.get_dummies(датафрейм, columns=['признак', 'признак 2', …], dtype=int)
```

```
df_new = pd.get_dummies(df, columns=['reg'], dtype=int)
```

df

	country	GDP	reg
0	Malta	25.29	S
1	Romania	382.77	E
2	Spain	1722.75	S
3	Belgium	889.83	W
4	Norway	485.66	N



df_new

	country	GDP	reg_S	reg_E	reg_W	reg_N
0	Malta	25.29	1	0	?	0
1	Romania	382.77	0	1	?	0
2	Spain	1722.75	1	0	?	0
3	Belgium	889.83	0	0	?	0
4	Norway	485.66	0	0	?	1

ЧТО БУДЕТ СТОЯТЬ НА МЕСТЕ «?» В ПРИЗНАКЕ REG_W?

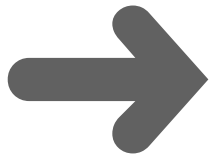
LABEL ENCODER

```
from sklearn.preprocessing import LabelEncoder
датафрейм['новый признак'] = LabelEncoder().fit_transform(датафрейм['признак'])
```

```
from sklearn.preprocessing import LabelEncoder
df['reg_new'] = LabelEncoder().fit_transform(df['reg'])
```

df

	country	GDP	reg
0	Malta	25.29	S
1	Romania	382.77	E
2	Spain	1722.75	S
3	Belgium	889.83	W
4	Norway	485.66	N



df

	country	GDP	reg	reg_new
0	Malta	25.29	S	2
1	Romania	382.77	E	0
2	Spain	1722.75	S	2
3	Belgium	889.83	W	3
4	Norway	485.66	N	1

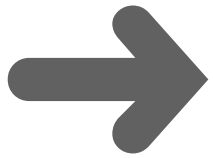
ORDINAL ENCODER

```
from sklearn.preprocessing import OrdinalEncoder
дф['новый признак'] = OrdinalEncoder(categories=[['знач 1', …]]).fit_transform(дф[['признак']])
```

```
from sklearn.preprocessing import OrdinalEncoder
df['reg_new'] = OrdinalEncoder(categories=[['N', 'W', 'S', 'E']]).fit_transform(df[['reg']])
```

df

	country	GDP	reg
0	Malta	25.29	S
1	Romania	382.77	E
2	Spain	1722.75	S
3	Belgium	889.83	W
4	Norway	485.66	N



df

	country	GDP	reg	reg_new
0	Malta	25.29	S	2
1	Romania	382.77	E	3
2	Spain	1722.75	S	2
3	Belgium	889.83	W	1
4	Norway	485.66	N	0