ОПИСАТЕЛЬНЫЕ СТАТИСТИКИ

ОПИСАТЕЛЬНЫЕ СТАТИСТИКИ

МЕРЫ ЦЕНТРАЛЬНОЙ ТЕНДЕНЦИИ

описываю типичное наблюдение в данных

- Среднее арифметическое
- Медиана
- Мода

КВАРТИЛИ

сегментируют данные

МЕРЫ ВАРИАТИВНОСТИ

описывают разброс данных

- Размах
- Интерквартильный размах
- Дисперсия
- Стандартное отклонение
- Количество уникальных значений

Для столбцов типа `int64` и `float64`:

```
датафрейм.describe()
```

	признак 1	...
count	кол-во не NaN значений	...
mean	среднее арифметическое	...
std	стандартное отклонение	...
min	минимум (нулевой квартиль)	...
25%	первый квартиль	...
50%	медиана (второй квартиль)	...
75%	третий квартиль	...
max	максимум (четвертый квартиль)	...

Для столбцов типа `object`:

```
датафрейм.describe(include=object)
```

	признак 1	...
count	кол-во не NaN значений	...
nunique	кол-во уникальных значений	...
top	мода	...
freq	частота моды	...

МЕРЫ ЦЕНТРАЛЬНОЙ ТЕНДЕНЦИИ

СРЕДНЕЕ АРИФМЕТИЧЕСКОЕ

`.mean()`

- Сумма деленная на количество:

$$\bar{x} = \frac{\Sigma x_i}{n}$$

- Рассчитывается для **количественных признаков**
- Рассчитывается для **категориальных бинарных**, закодированных 1/0 или True/False (показывает долю 1/True)
- **Не устойчив** к выбросам

МЕДИАНА

`.median()`

- Срединная МЦТ, которая делит данные пополам

Пример 1: 3 1 2 5 4 → 1 2 **3** 4 5

Пример 2: 3 1 2 4 → 1 2 3 4 → 2.5

- Рассчитывается для **количественных признаков**
- **Устойчив** к выбросам

МОДА

`.mode()`

- Для **категориальных**: самое частое значение в данных

Пример 1: A B C A D → A

Пример 2: A B C A C → A , C

- Для **количественных**: интервал значений с наибольшей частотой (гистограмма)

СРЕДНЕЕ И МЕДИАНА

Выбросы - это экстремальные значения, которые значительно отличаются от основного набора данных.

Рассчитайте средние и медианы для каждой из выборок:

ПРИМЕР	СРЕДНЕЕ	МЕДИАНА
1 2 3 4	?	?
1 2 3 4 100	?	?
-100 1 2 3 4	?	?

- **СРЕДНЕЕ СТРЕМИТСЯ К ВЫБРОСАМ**
- **МЕДИАНА СТРЕМИТСЯ ОТ ВЫБРОСОВ**

A2

Вар 2: Какую меру измерения центральной тенденции корректно использовать при работе с категориальной бинарной переменной, которая отвечает за пол респондента и закодирована числами 0 и 1?

- Медиана
- Среднее арифметическое
- Размах
- Интерквартильное расстояние

Вар 3: Какую меру измерения центральной тенденции корректно использовать при работе с номинальной переменной, которая отвечает за профессию респондента?

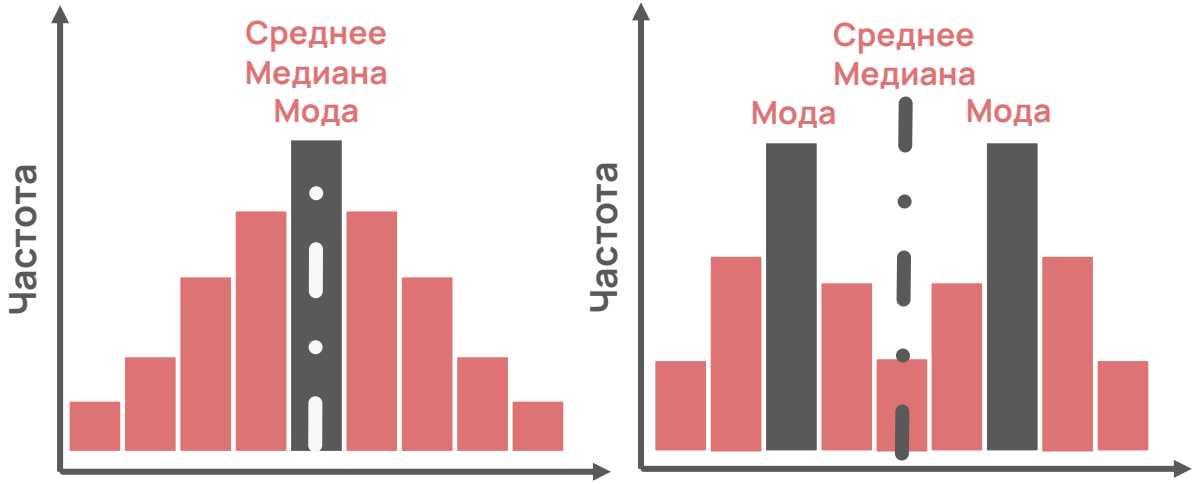
- Среднее арифметическое
- Дисперсия
- Мода
- Количество уникальных значений

ДЕМО: Исследователь анализирует переменную «время ожидания пациента в приемном покое (в минутах)» в крупной городской больнице. Большинство пациентов ждали относительно недолго (от 10 до 20 минут), но есть и те, чье время ожидания было значительно выше среднего (более 2 часов).
Какую меру центральной тенденции следует использовать для описания типичного наблюдения в данных?

- Мода
- Стандартное отклонение
- Среднее арифметическое
- Медиана

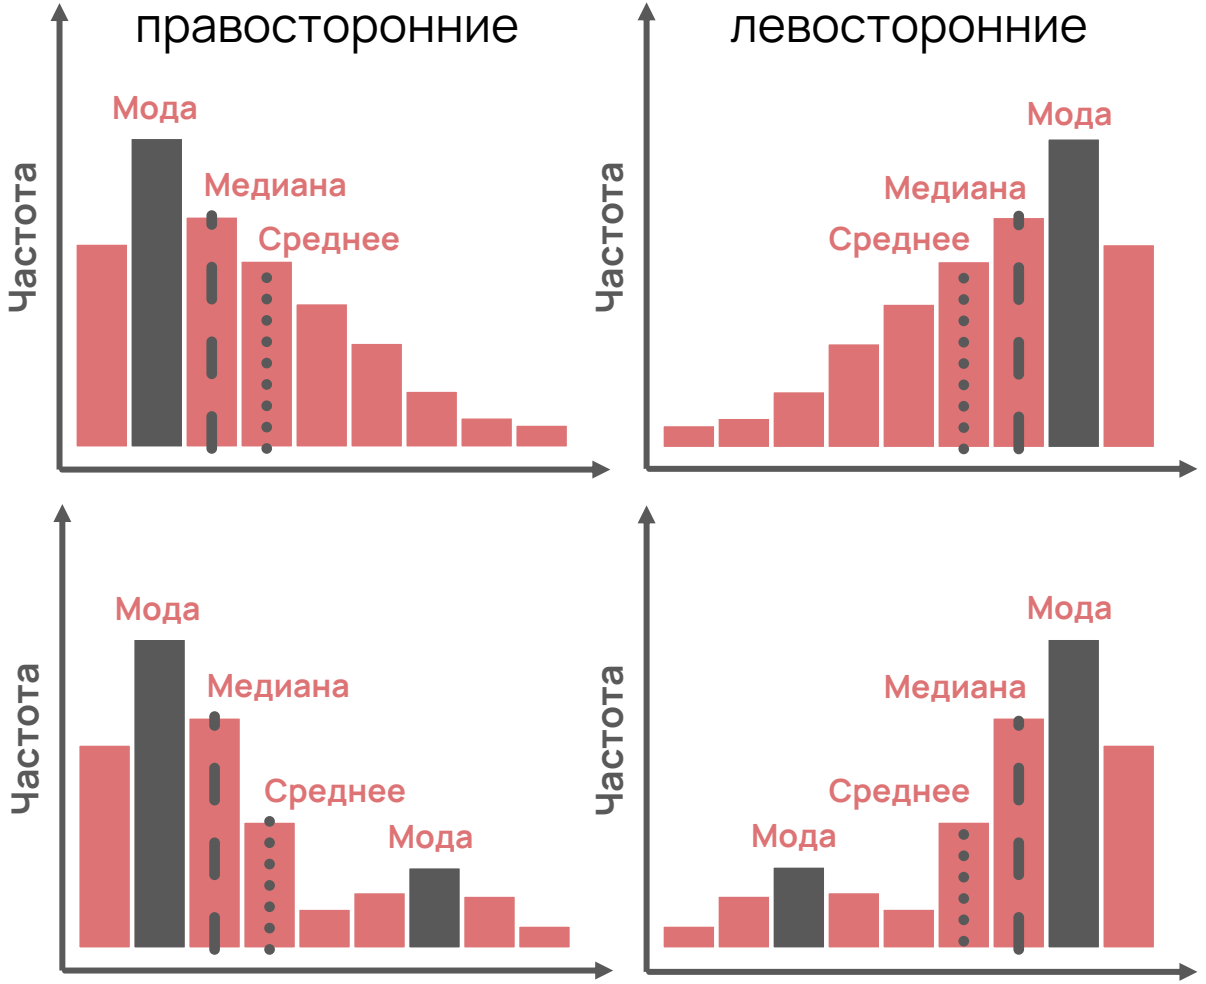
РАСПРЕДЕЛЕНИЕ ДАННЫХ

СИММЕТРИЧНЫЕ РАСПРЕДЕЛЕНИЯ



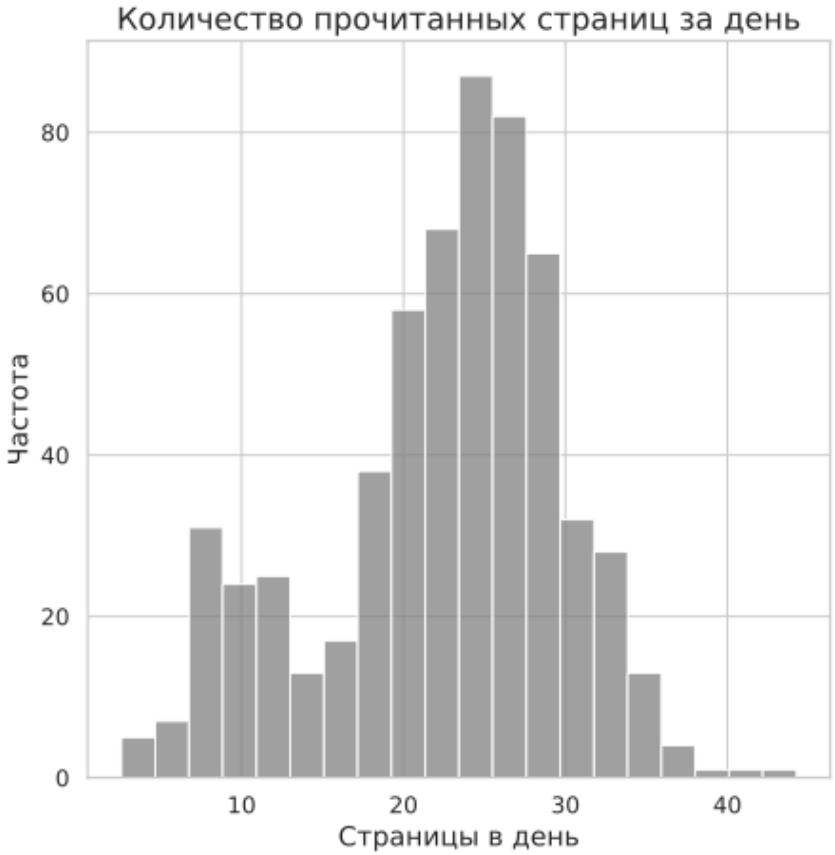
- Среднее стремится к выбросам
- Медиана стремится от выбросов
- Мода каждый из пиков

АСИММЕТРИЧНЫЕ РАСПРЕДЕЛЕНИЯ



A3

Какое утверждение наиболее точно отражает информацию, представленную на графике?



- Распределение симметричное, без выбросов.
- Распределение правосторонне скошено (с хвостом вправо).
- Медиана находится выше среднего значения.
- Большинство участников читают от 20 до 30 страниц в день.

КВАРТИЛИ

НУЛЕВОЙ КВАРТИЛЬ (Q_0)

`.quantile(0)` `.min()`

- Минимум
- 100% данных не меньше чем Q_0
- 0% данных меньше чем Q_0

ВТОРОЙ КВАРТИЛЬ (Q_2)

`.quantile(0.5)` `.median()`

- Медиана
- 50% данных больше чем Q_2
- 50% данных меньше чем Q_2

ТРЕТИЙ КВАРТИЛЬ (Q_3)

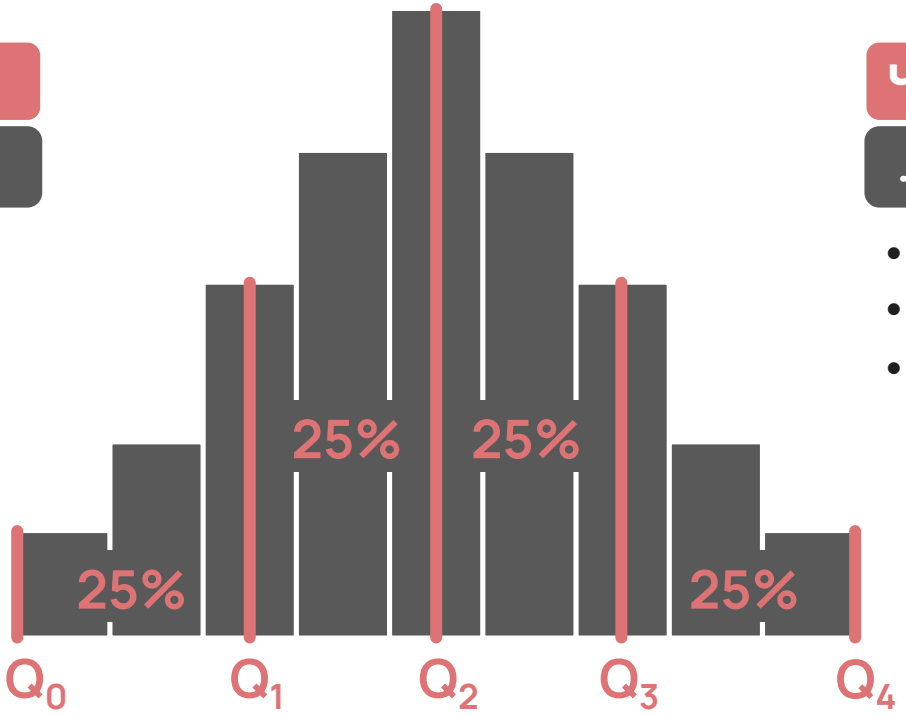
`.quantile(0.75)`

- 25% данных больше чем Q_3
- 75% данных меньше чем Q_3

ПЕРВЫЙ КВАРТИЛЬ (Q_1)

`.quantile(0.25)`

- 75% данных больше чем Q_1
- 25% данных меньше чем Q_1



ЧЕТВЕРТЫЙ КВАРТИЛЬ (Q_4)

`.quantile(1)` `.max()`

- Максимум
- 0% данных больше чем Q_4
- 100% данных не больше чем Q_4

КЕЙС. КВАРТИЛИ

КЕЙС

Исследователь собрал данные по ВВП в млрд долларов (**gdp**) для всех стран мира и рассчитал значение квартилей для этого признака. Интерпретируйте каждое из полученных значений.

```
df['gdp'].quantile(0)
```

```
0.28
```

```
df['gdp'].quantile(0.25)
```

```
14.2
```

```
df['gdp'].quantile(0.5)
```

```
47.74
```

```
df['gdp'].quantile(0.75)
```

```
300.0
```

```
df['gdp'].quantile(1)
```

```
29185.0
```

МЕРЫ ВАРИАТИВНОСТИ (1)

КОЛИЧЕСТВО УНИКАЛЬНЫХ ЗНАЧЕНИЙ

```
.nunique()
```

- Показывает разброс **категориального признака**

РАЗМАХ

```
.max()-.min()
```

- Диапазон в котором лежит 100% данных:

$$\mathbf{RANGE = MAX - MIN}$$

- Рассчитывается для **количественных признаков**
- **Не устойчив** к выбросам

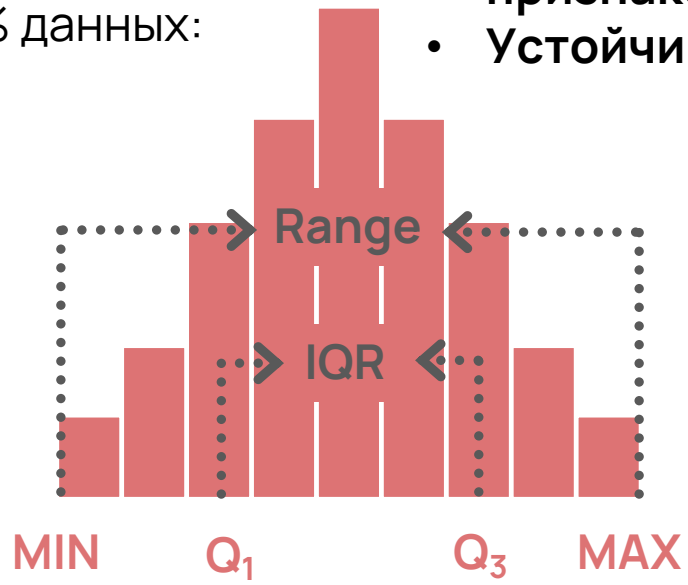
ИНТЕРКВАРТИЛЬНЫЙ РАЗМАХ

```
.quantile(0.75)-.quantile(0.25)
```

- Диапазон в котором лежит 50% центральных данных:

$$\mathbf{IQR = Q_3 - Q_1}$$

- Рассчитывается для **количественных признаков**
- **Устойчив** к выбросам



МЕРЫ ВАРИАТИВНОСТИ (2)

ДИСПЕРСИЯ

`.var()`

- Усредненный квадрат отклонений данных от среднего арифметического:

$$\sigma^2 = \frac{\Sigma(x_i - \bar{x})^2}{n}$$

- Рассчитывается для **количественных признаков**
- **Не устойчив** к выбросам

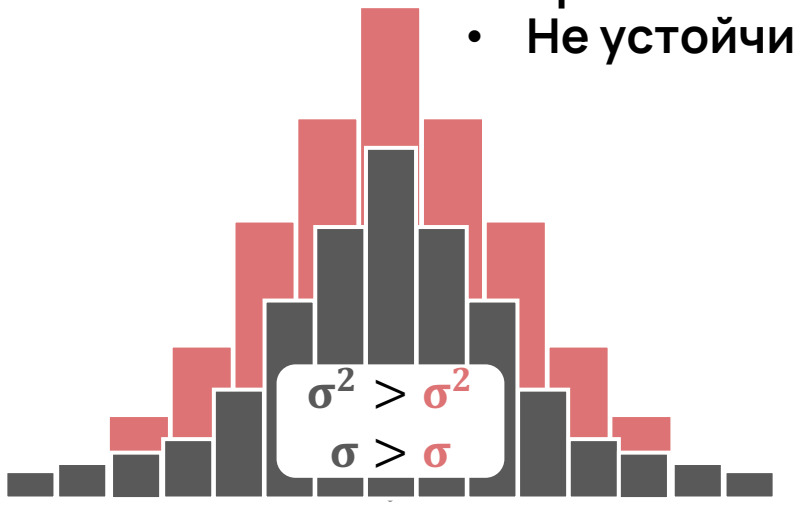
СТАНДАРТНОЕ ОТКЛОНЕНИЕ

`.std()`

- Усредненное отклонение данных от среднего арифметического :

$$\sigma = \sqrt{\frac{\Sigma(x_i - \bar{x})^2}{n}}$$

- Рассчитывается для **количественных признаков**
- **Не устойчив** к выбросам



A2

Вар 1: В наборе данных информация об уровне владения иностранным языком студентов первого курса закодирована по системе CEFR (A1, A2, B1, B2, C1 или C2). Какую меру вариативности корректно использоваться для данного признака?

- Стандартное отклонение
- Мода
- Количество уникальных значений
- Медиана

Вар 9: В данных есть переменная "суммарная стоимость покупок пользователя интернет магазина за прошлый месяц (в рублях с копейками, дробь)". Какую описательную статистику некорректно рассчитывать для этой переменной?

- Количество уникальных значений
- Мода
- Дисперсия
- Среднее арифметическое

Вар 6: Какая мера разброса данных менее всего чувствительна к выбросам?

- Межквартильный размах / интерквартильный размах
- Размах
- Дисперсия
- Среднеквадратичное отклонение

КЕЙС. ОПИСАТЕЛЬНЫЕ СТАТИСТИКИ

КЕЙС

В таблице собранны **A** характеристики стран. Ответьте на вопросы ниже с помощью ОС.

country – название страны
gdp – ВВП (в млрд долларов)
gov – система правления
dem – является ли режим демократическим

A

	country	gdp	gov	dem
0	Poland	944.86	spr	1
1	Cyprus	36.33	pr	1
2	Sudan	30.9	par	0
...	...	...	...	...

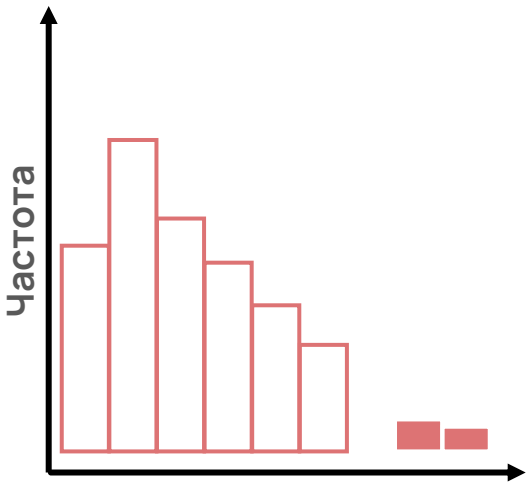
1. Как описать типичный мировой ВВП (**gdp**)?
2. Какая амплитуда изменения мирового ВВП (**gdp**)?
3. Как узнать типичную систему правления (**gov**) для стран?
4. Как узнать процент стран с демократической системой правления (*1*; **dem**)?
5. Как узнать насколько в среднем ВВП (**gdp**) отличается от среднего значения?

ВЫБРОСЫ

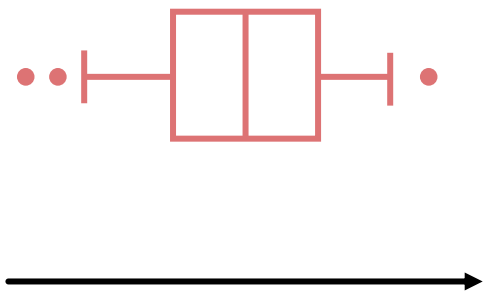
ВЫБРОСЫ

Выбросы - это экстремальные значения, которые значительно отличаются от основного набора данных.

ГИСТОГРАММА



ЯЩИК С УСАМИ



СКРИПИЧНЫЙ ГРАФИК

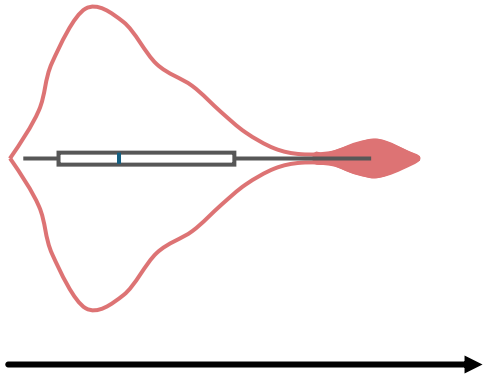
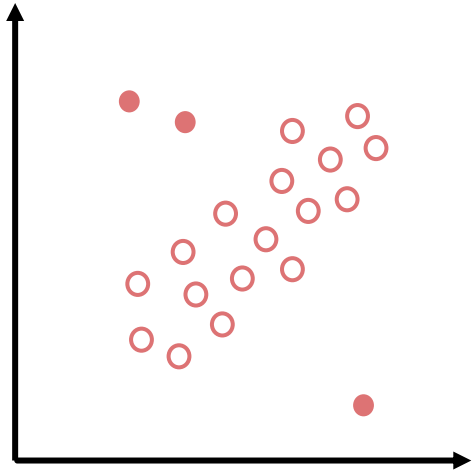


ДИАГРАММА РАССЕЯНИЯ



ГРАНИЦЫ ВЫБРОСОВ. МЕТОД N*STD

Обозначим колонку:

```
col = датафрейм['признак']
```

1. Находим среднее арифметическое:

```
avg = col.mean()
```

2. Находим стандартное отклонение:

```
std = col.std()
```

3. Левая граница выбросов:

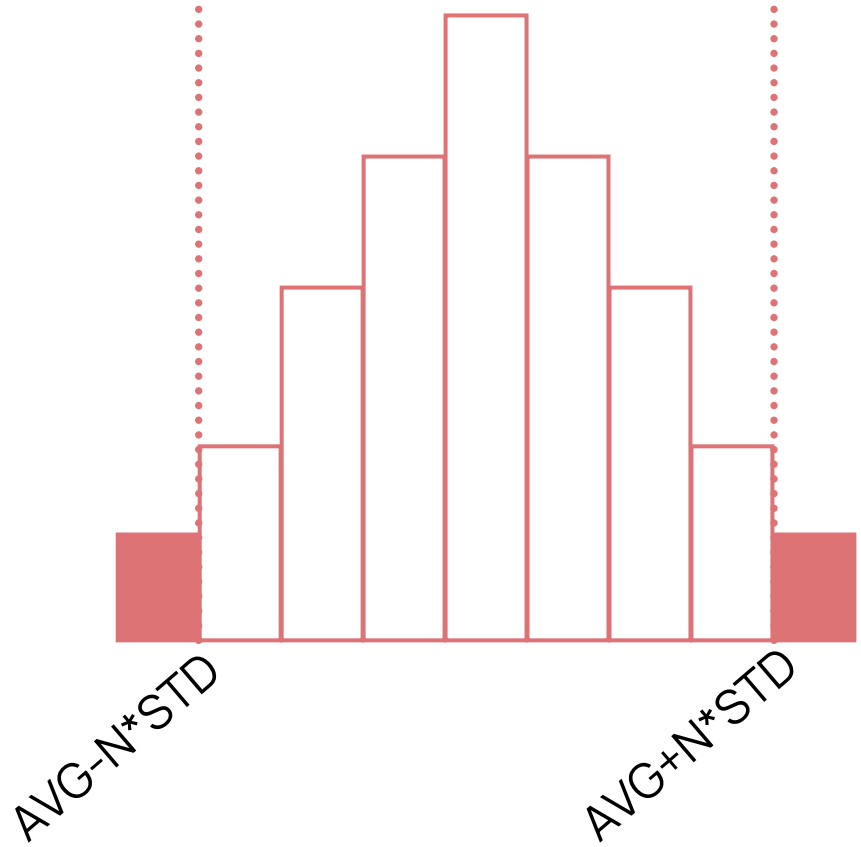
```
left = avg - N*std
```

4. Правая граница выбросов:

```
right = avg + N*std
```

Чистые данные:

```
датафрейм[col.between(left, right)]
```



ГРАНИЦЫ ВЫБРОСОВ. МЕТОД 1.5*IQR

Обозначим колонку:

```
col = датафрейм['признак']
```

1. Находим первый квартиль:

```
q1 = col.quantile(0.25)
```

2. Находим третий квартиль:

```
q3 = col.quantile(0.75)
```

3. Находим интерквартильный размах:

```
iqr = q3 - q1
```

4. Левая граница выбросов:

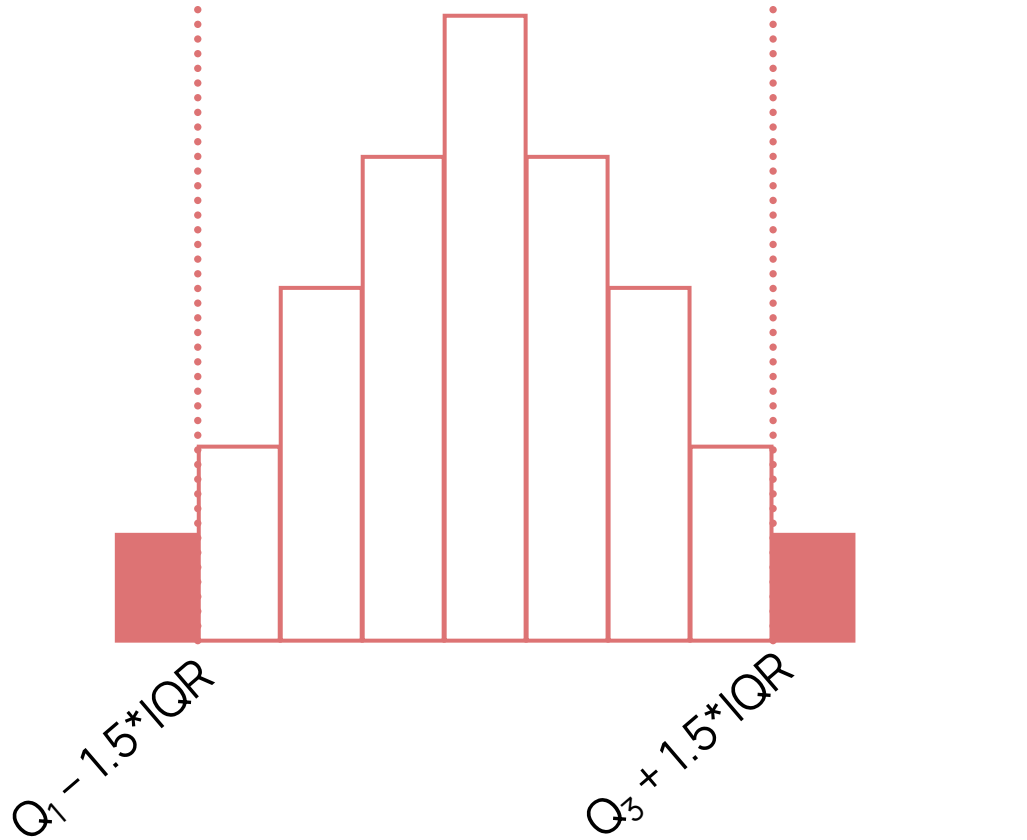
```
left = q1 - 1.5*iqr
```

5. Правая граница выбросов:

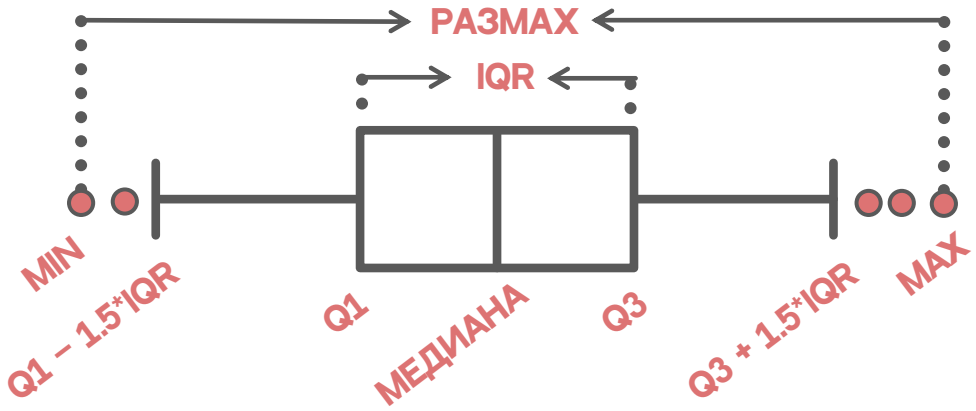
```
right = q3 + 1.5*iqr
```

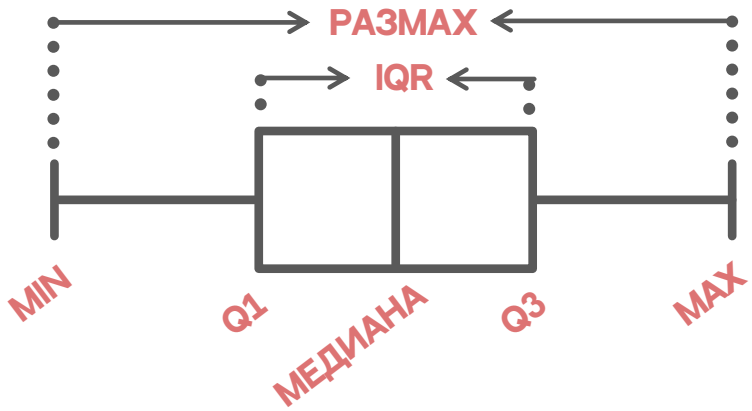
Чистые данные:

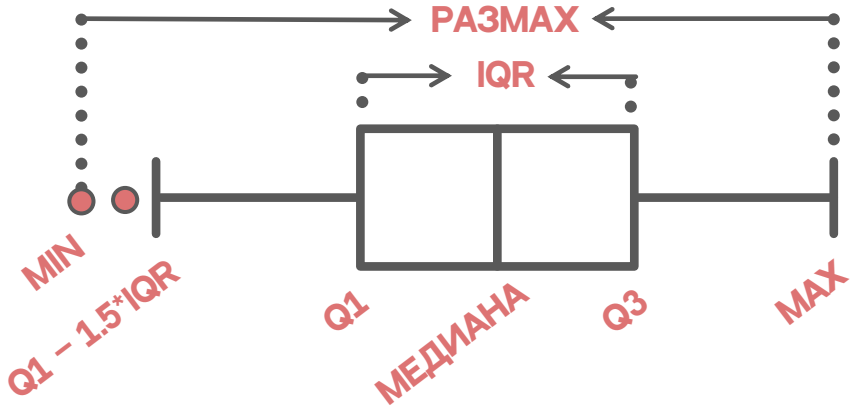
```
датафрейм[col.between(left, right)]
```

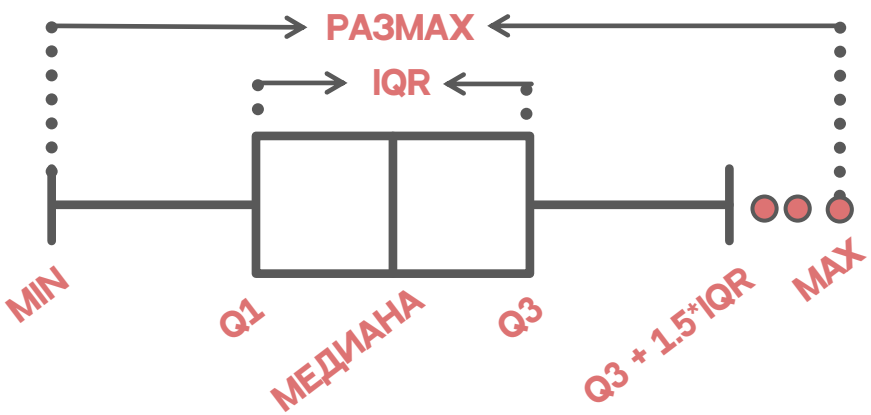


ЯЩИК С УСАМИ


РАЗМАХ
IQR
MIN
Q1 − 1.5*IQR
Q1
МЕДИАНА
Q3
Q3 + 1.5*IQR
MAX


РАЗМАХ
IQR
MIN
Q1
МЕДИАНА
Q3
MAX


РАЗМАХ
IQR
MIN
Q1 − 1.5*IQR
Q1
МЕДИАНА
Q3
MAX

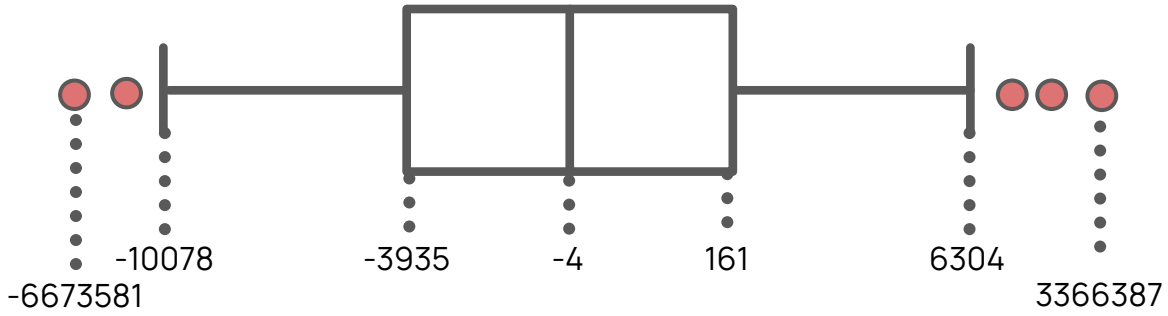

РАЗМАХ
IQR
MIN
Q1
МЕДИАНА
Q3
Q3 + 1.5*IQR
MAX

КЕЙС. ЯЩИК С УСАМИ

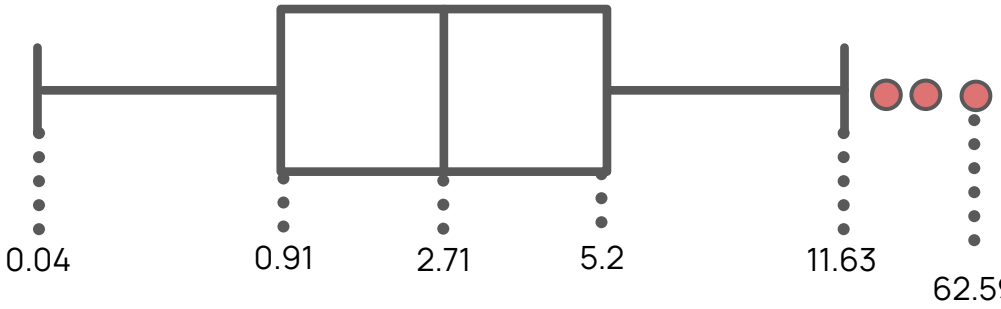
КЕЙС

Аналитик визуализировал показателя по всем странам мира за 2024 год. Интерпретируйте значения ящиков с усами для каждого показателя.

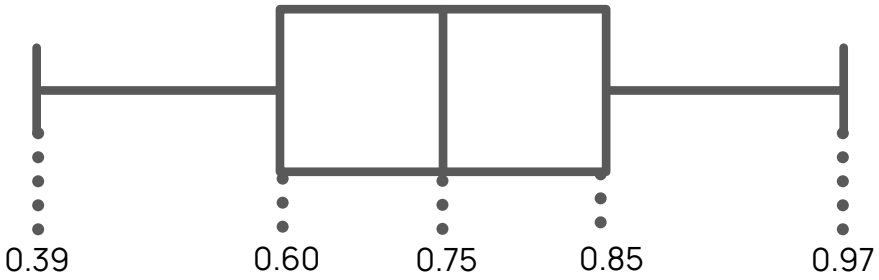
САЛЬДО МИГРАЦИИ (ЧЕЛОВЕК)



ВЫБРОСЫ CO2 (ТОННЫ)



ИНДЕКС ЧЕЛОВЕЧЕСКОГО РАЗВИТИЯ



ПРОПУСКИ

ПОДСЧЕТ ПРОПУСКОВ

КЕЙС

Исследователь собрал характеристики по 189 странам в таблице **A**. **Нужно посчитать количество пропусков в каждом признаке.**

country – название страны
gdp – ВВП (в млрд долларов)
reg – регион
co2 – выбросы CO2

A

	country	gdp	reg	co2
0	Malta	25.29	E	NaN
1	Norway	NaN	E	Mid
2	Sudan	30.9	Af	NaN
3	Brazil	2179.41	SA	High
...	...	...	..	...

КОЛИЧЕСТВО NAN

```
A.isna().sum()
```

	0
country	0
gdp	25
reg	0
co2	32

ДОЛЯ NAN

```
A.isna().mean()
```

	0
country	0
gdp	0.132275
reg	0
co2	0.169312

Если нужно посмотреть на наблюдения с пропусками:

```
датафрейм[датафрейм['признак'].isna()]
```

Если нужно посмотреть на наблюдения без пропусков:

```
датафрейм[датафрейм['признак'].isna()==False]
```

РАБОТА С ПРОПУСКАМИ

Если пропусков (NaN) **более 40%**:

- Удаляем признак

```
датафрейм = датафрейм.drop(columns=['признак 1', …])
```

Если пропусков (NaN) в признаке **не более 40%**:

- Удалить строчки с пропусками:

```
датафрейм = датафрейм.dropna(subset=['признак 1', …])
```

- Заменить пропуски на МЦТ:
  - **количественный признак →** медиана, среднее арифметическое
  - **категориальный признак →** мода

```
датафрейм['признак'] = датафрейм['признак'].fillna(<МЦТ>)
```

ЗАМЕНА ПРОПУСКОВ

КОЛИЧЕСТВЕННЫЙ ПРИЗНАК

1. Рассчитываем МЦТ:

```
med = A['gdp'].median()
```

```
44.25
```

2. Заменяем пропуски :

```
A['gdp_clean'] = A['gdp'].fillna(med)
```

	country	gdp	...	gdp_clean
0	Malta	25.29	...	25.29
1	Norway	NaN	...	44.25
2	Sudan	30.9	...	30.9
3	Brazil	2179.41	...	2179.41
...	...	...	...	...

КАТЕГОРИАЛЬНЫЙ ПРИЗНАК

1. Рассчитываем МЦТ:

```
m = A['co2'].mode()[0]
```

```
'Mid'
```

2. Заменяем пропуски :

```
A['co2_clean'] = A['co2'].fillna(m)
```

	country	...	co2	co2_clean
0	Malta	...	NaN	Mid
1	Norway	...	Mid	Mid
2	Sudan	...	NaN	Mid
3	Brazil	...	High	High
...	...	...	...	

ЗАМЕНА ПРОПУСКОВ ПО ГРУППЕ (1)

КОЛИЧЕСТВЕННЫЙ ПРИЗНАК

Заменим пропуски в ВВП (**gdp**) на медиану с учетом региона (**reg**) к которому относится страна.

1. Рассчитываем МЦТ для каждой группы:

```
med = A.groupby('reg')['gdp'].transform('median')
```

	gdp	country/reg
0	132.00	Malta/E
1	132.00	Norway/E
2	18.80	Sudan/Af
3	144.80	Brazil/SA
...	...	...

2. Заменяем NaN с учетом региона:

```
A['gdp_clean'] = A['gdp'].fillna(med)
```

	country	gdp	reg	...	gdp_clean
0	Malta	25.29	E	...	25.29
1	Norway	NaN	E	...	132.00
2	Sudan	30.9	Af	...	30.9
3	Brazil	2179.41	SA	...	2179.41
...	...	...	...	...	...

ЗАМЕНА ПРОПУСКОВ ПО ГРУППЕ (2)

КАТЕГОРИАЛЬНЫЙ ПРИЗНАК

Заменим пропуски в количестве выбросов CO2 (**co2**) на моду с учетом региона (**reg**) к которому относится страна.

1. Рассчитываем МЦТ для каждой группы:

```
def coded(x):
  return x.mode()[0]
```

```
m = A.groupby('reg')['co2'].transform(coded)
```

	co2	country/reg
0	Mid	Malta/E
1	Mid	Norway/E
2	Low	Sudan/Af
3	Mid	Brazil/SA
...	...	...

2. Заменяем NaN с учетом региона:

```
A['co2_clean'] = A['co2'].fillna(m)
```

	country	...	reg	co2	...	co2_clean
0	Malta	...	E	NaN	...	Mid
1	Norway	...	E	Mid	...	Mid
2	Sudan	...	Af	NaN	...	Low
3	Brazil	...	SA	High	...	High
...	...	...	...	...	...	...