КОРРЕЛЯЦИЯ

КОРРЕЛЯЦИЯ

Корреляция – мера статистической связи между двумя признаками.



Если корреляция между A и B **отрицательная**:

- если A ↑, то и B ↓
- если A ↓ , то и B ↑

Если корреляция между A и B **положительная**:

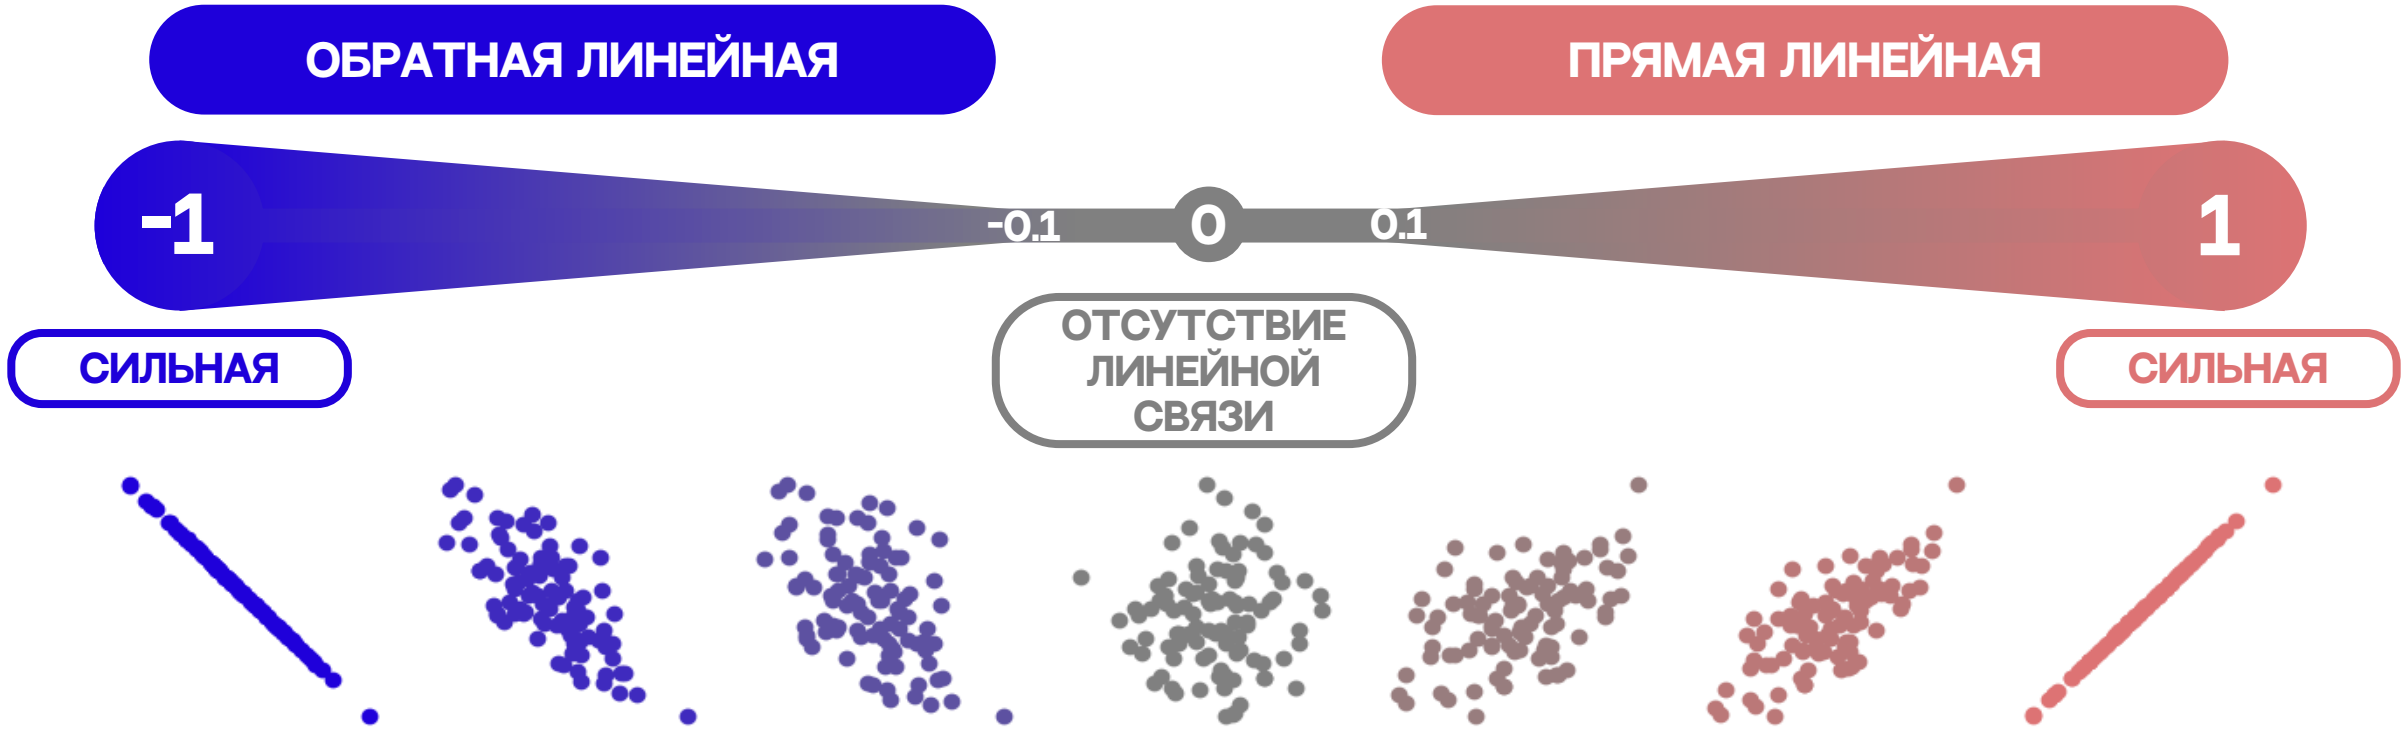
- если A ↑, то и B ↑
- если A ↓ , то и B ↓

Корреляция не говорит о причинно-следственных связях (*Correlation is not causation*). При интерпретации корреляции **НЕКОРРЕКТНО использовать слова «влияет», «зависит», «причина» и т.д..**

КОРРЕЛЯЦИЯ ПИРСОНА

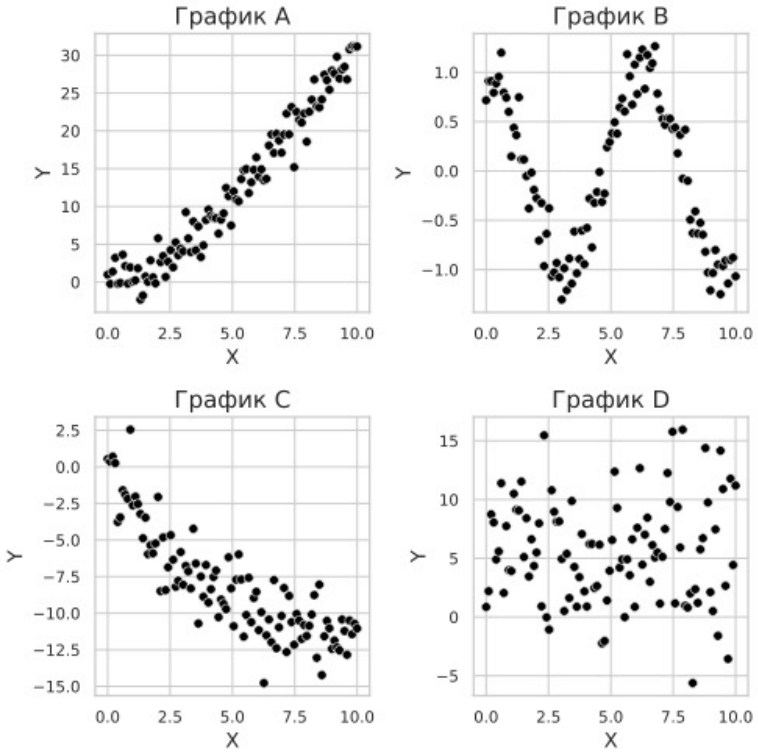
Корреляция Пирсона – мера линейной связи между двумя признаками:

- интерпретируется только между количественными признаками
- чувствительна к выбросам

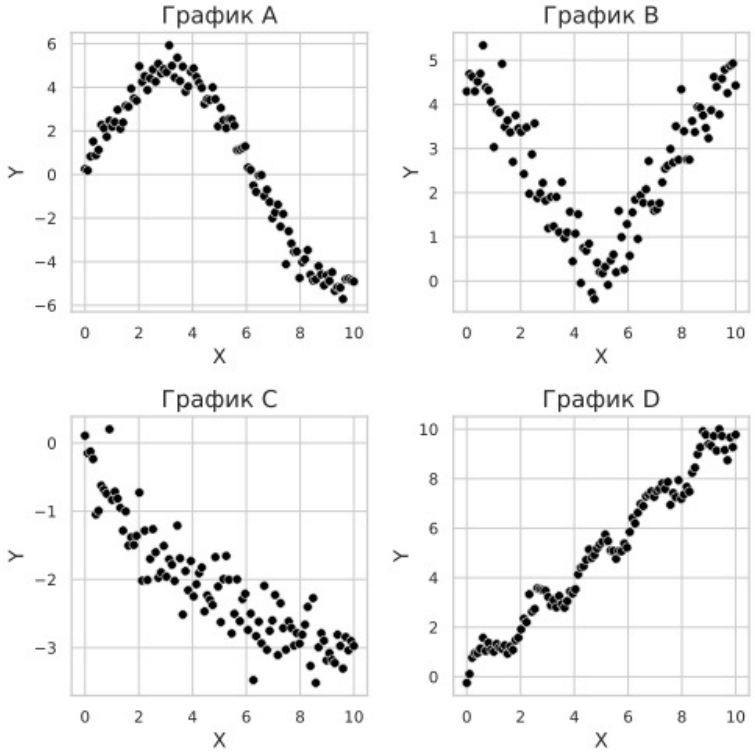


A5_1_3

Вар 1: Ниже изображены четыре графика зависимости переменной Y от X. На каком из них коэффициент Пирсона будет больше по модулю?



Вар 3: Ниже изображены четыре графика зависимости переменной Y от X. На каком из них коэффициент Пирсона будет меньше по модулю?



A4_3_4

Вар 3: Аналитик посчитал коэффициент корреляции Пирсона между доходом и количеством заказов на онлайн-платформе. Результат: 0.002.
Какой вывод наиболее корректен?

- Существует слабая отрицательная линейная связь между доходом и заказами.
- Существует слабая положительная монотонная связь между доходом и заказами.
- Существует нелинейная связь между доходом и заказами.
- Линейная связь между доходом и количеством заказов почти отсутствует.

Вар 4: Исследователь измерил корреляцию Пирсона между возрастом респондента и временем, проведённым в социальных сетях. Получил значение 1.
Какой вывод наиболее корректен?

- Существует сильная положительная линейная связь между возрастом и временем, проведённым в социальных сетях.
- Существует сильная положительная монотонная связь между возрастом респондента и временем, проведённым в социальных сетях.
- Связь между возрастом и временем, проведённым в социальных сетях отсутствует.
- Переменные “возраст респондента” и “время, проведенное в социальных сетях” принимают одинаковые значения.

ПАРНАЯ КОРРЕЛЯЦИИ ПИРСОНА

```
датафрейм['признак 1'].corr(датафрейм['признак 2'])
```

КЕЙС

Исследователь рассчитал коэффициент корреляции Пирсона между ВВП (**GDP**) и индексом демократии (**DEM**). **Проинтерпретируйте полученное значение**.

```
df['GDP'].corr(df['DEM'])
```

```
0.736345
```

country – название страны
GDP – ВВП
OIL – объем импорта нефти
DEM – индекс демократии
...
CO2 – уровень выбросов CO2 (1-низкий, 2-средний, 3-высокий)

	country	GDP	OIL	DEM	...	CO2
0	Germany	48000	2.1	8.68	...	2
1	India	2000	12.5	6.61	...	3
2	Russia	11000	60.3	3.31	...	2
...	...	...	...	...	...	...

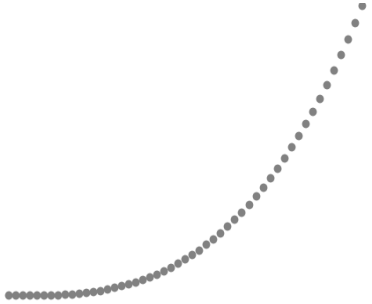
ЗАВИСИМОСТИ В ДАННЫХ

МОНОТОННЫЕ

ЛИНЕЙНАЯ



СТЕПЕННАЯ



КВАДРАТНЫЙ КОРЕНЬ



АРКСИНУС

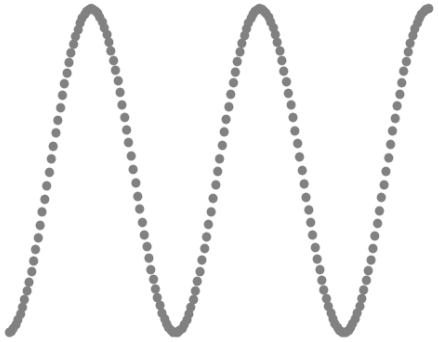


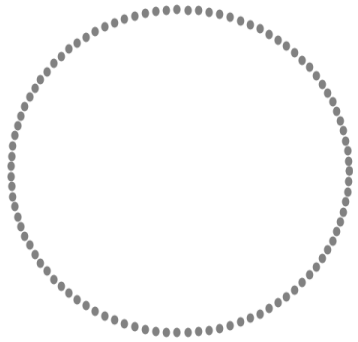
НЕМОНОТОННЫЕ

КВАДРАТИЧНАЯ



ЦИКЛИЧЕСКАЯ

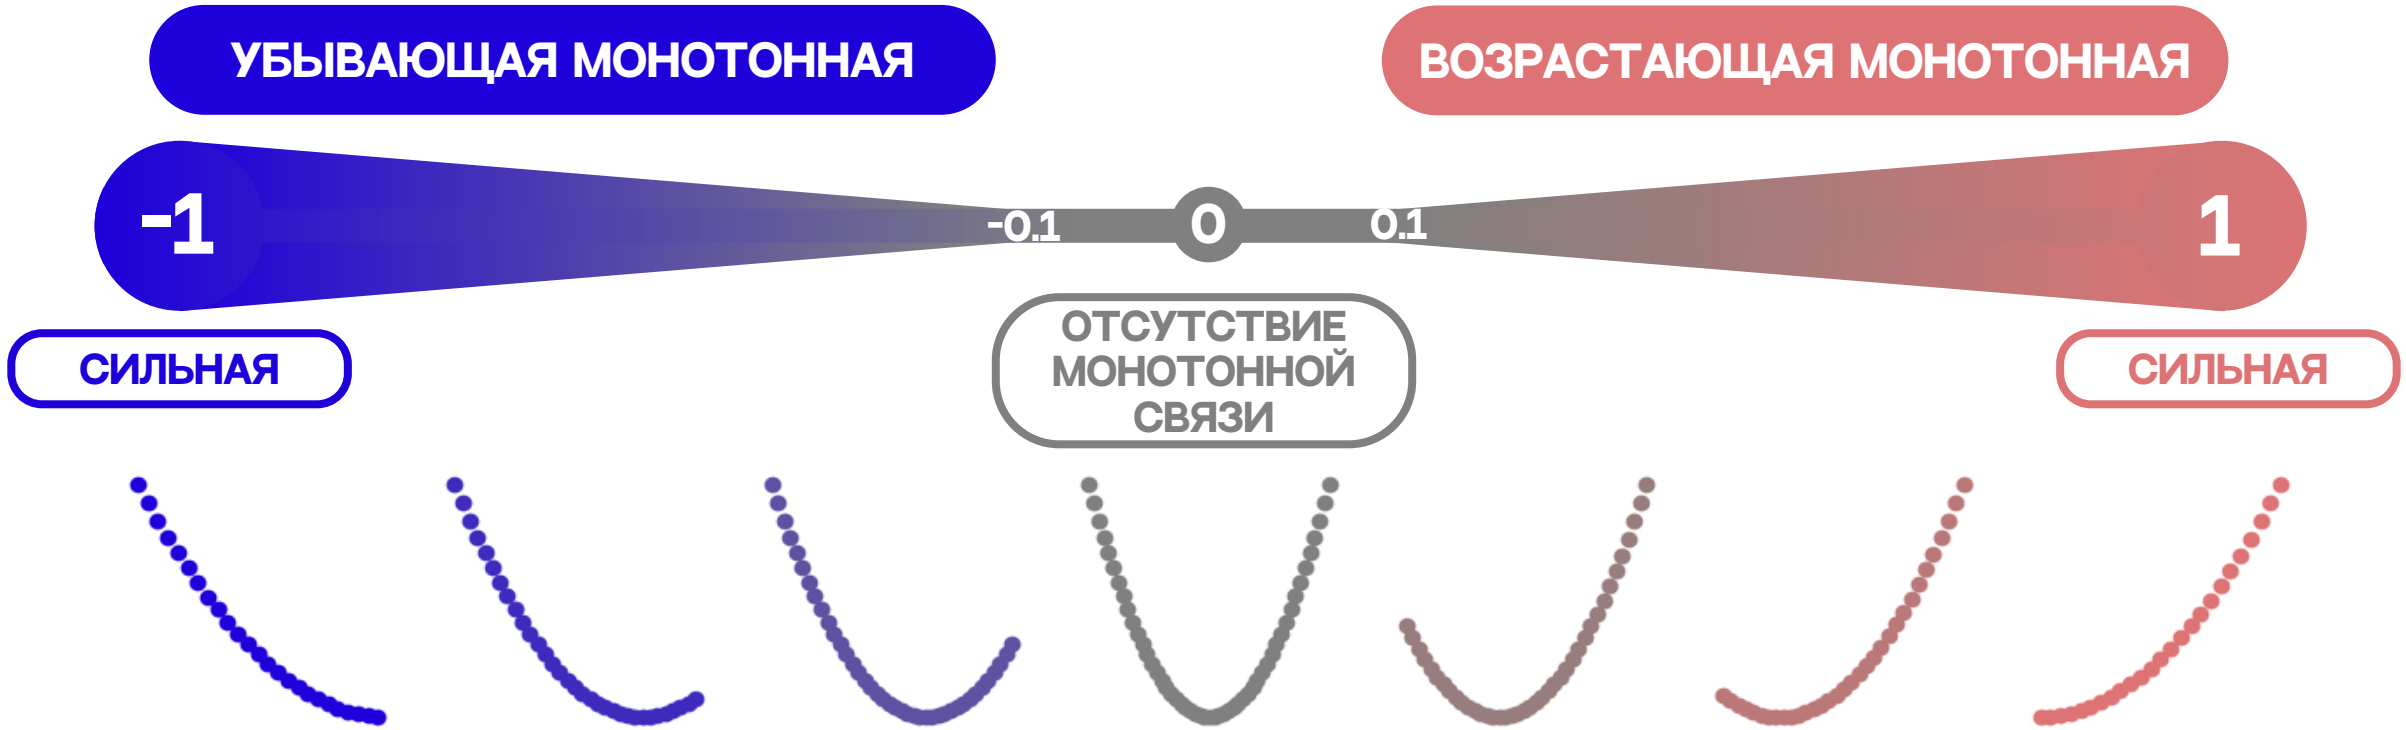




КОРРЕЛЯЦИЯ СПИРМАНА

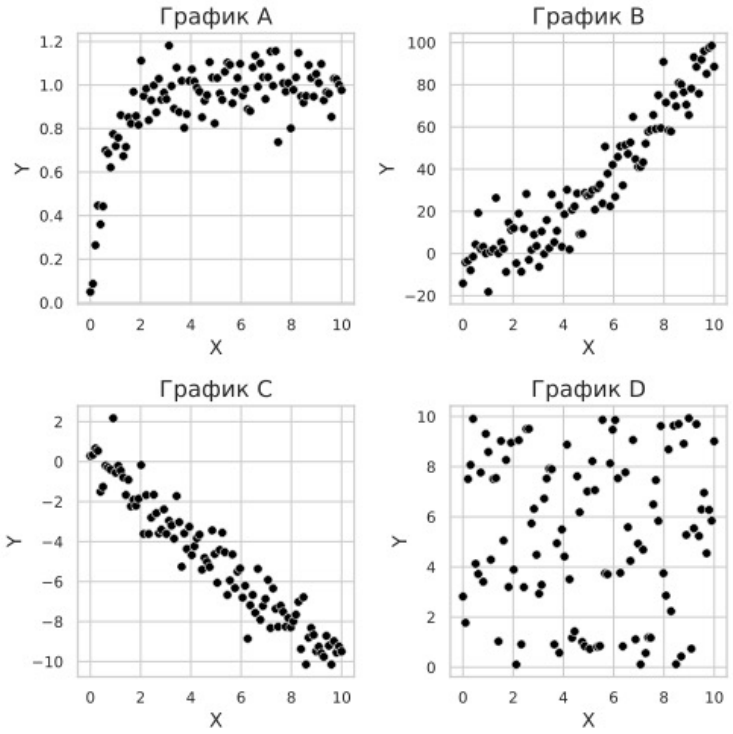
Корреляция Спирмана – мера монотонной связи между двумя признаками:

- интерпретируется между количественным и категориальными признаками
- устойчива к выбросам

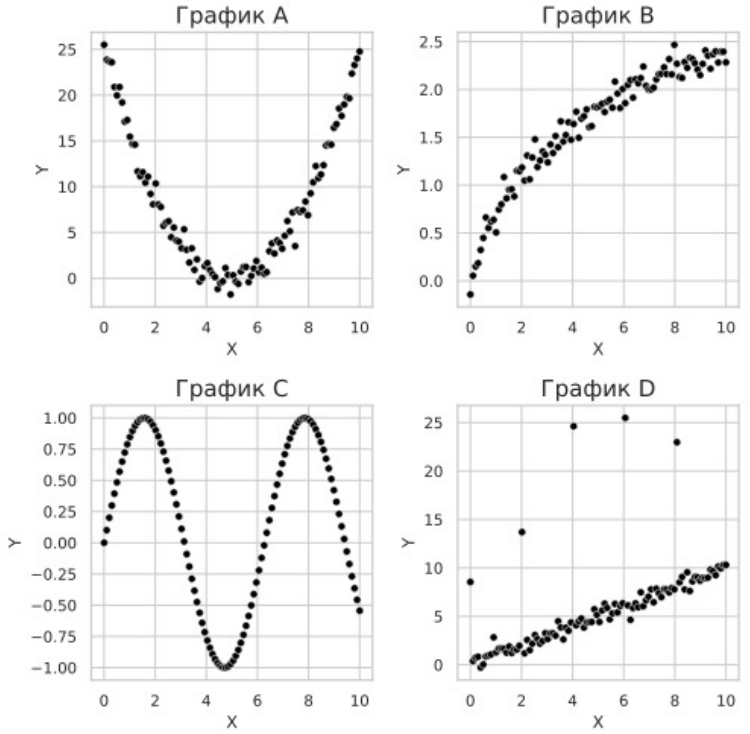


A5_2_5

Вар 2: Ниже изображены четыре графика зависимости переменной Y от X. На каком из них коэффициент Спирмана будет больше по модулю?



Вар 5: Ниже изображены четыре графика зависимости переменной Y от X. На каком из них разница (по модулю) между коэффициентами Спирмана и Пирсона будет наибольшей?



A4_1_2

Вар 1: Аналитик получил коэффициент корреляции Спирмана между количеством часов сна и уровнем концентрации = -0.75.
Какой вывод наиболее корректен?

- Количество часов сна отрицательно влияет на уровень концентрации (существует причинно-следственная связь)
- Существует сильная отрицательная линейная связь между количеством сна и концентрацией.
- Связь между количеством сна и концентрацией отсутствует.
- Существует сильная монотонная зависимость между количеством сна и концентрацией.

Вар 2: Исследователь получил коэффициент корреляции Спирмана между уровнем тревожности и количеством кофе, выпитого в день, равный 0.25.
Какой вывод наиболее корректен?

- Связь между тревожностью и количеством кофе – отрицательная.
- Существует сильная положительная линейная связь между тревожностью и кофе.
- Чем меньше человек пьёт кофе, тем ниже уровень тревожности.
- Существует слабая положительная монотонная связь между тревожностью и количеством выпитого кофе.

ПАРНАЯ КОРРЕЛЯЦИИ СПИРМАНА

```
датафрейм['признак 1'].corr(датафрейм['признак 2'], method='spearman')
```

КЕЙС

Исследователь рассчитал коэффициент корреляции Спирмана между ВВП (**GDP**) и уровнем выбросов CO2 (**CO2**). **Проинтерпретируйте полученное значение**.

```
df['GDP'].corr(df['CO2'], method='spearman')
```

```
-0.567812
```

country – название страны
GDP – ВВП
OIL – объем импорт нефти
DEM – индекс демократии
...
CO2 – уровень выбросов CO2 (1-высокий, 2-средний, 3-низкий)

	country	GDP	OIL	DEM	...	CO2
0	Germany	48000	2.1	8.68	...	2
1	India	2000	12.5	6.61	...	1
2	Russia	11000	60.3	3.31	...	2
...	...	...	...	...	...	...

КОРРЕЛЯЦИОННАЯ МАТРИЦА

Корреляционная матрица – это таблица, которая показывает степень взаимосвязи между различными переменными:

- по центральной диагонали 1 (**автокорреляция** – корреляция переменной самой с собой)
- матрица симметрична относительно центральной диагонали

ПИРСОН

```
датафрейм.corr()
```

или

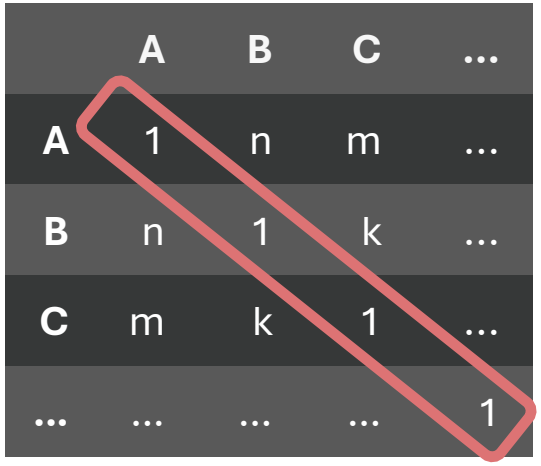
```
датафрейм.corr(numeric_only=True)
```

СПИРМАН

```
датафрейм.corr(method='spearman')
```

или

```
датафрейм.corr(numeric_only=True, method='spearman')
```



КОРРЕЛЯЦИОННАЯ МАТРИЦА

КЕЙС

Исследователь хочет узнать, какой признак имеет самую сильную монотонную связь с уровнем выбросов CO2 (**CO2**).

Строим корреляционную матрицу:

```
cm = df.corr(method='spearman')
```

	GDP	OIL	DEM	...	CO2
GDP	1	0.63	0.72	...	-0.57
OIL	0.63	1	0.23	...	0.04
DEM	0.72	0.23	1	...	-0.32
...	...	...	...	...	...
CO2	-0.57	0.04	-0.32	...	1

Извлекаем **CO2** и сортируем без учета знака:

```
cm['CO2'].sort_values(key=abs)
```

	CO2
OIL	0.04
...	...
MAN*	-0.85
CO2	1

MAN* - количество крупных производств