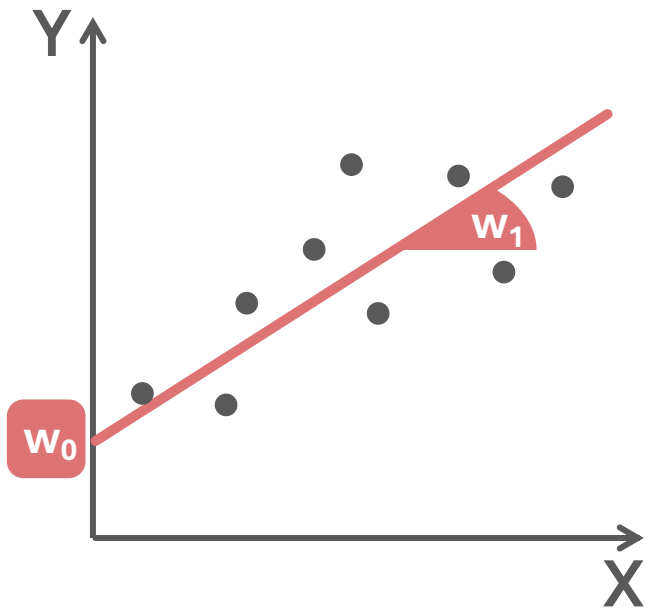
ЛИНЕЙНАЯ РЕГРЕССИЯ

ЛИНЕЙНАЯ РЕГРЕССИЯ

Линейная регрессия — это метод анализа данных, предназначенный для моделирования зависимости между одной или несколькими независимыми переменными (предикторами) и **количественной** зависимой переменной (целевым признаком).



Целевая/ зависимая переменная

Коэффициент независимой переменной

$$Y = w_0 + w_1 \times X_1$$

Свободный коэффициент

Предиктор/ независимая переменная

ВИДЫ ЛИНЕЙНЫХ РЕГРЕССИЙ

ОДНОФАКТОРНАЯ

$$Y = W_0 + W_1 \times X_1$$

КЕЙС

Модель, которая предсказывает объем двусторонней торговли между двумя странами (**MARKET**) на основе расстояния между столицами этих стран (**DIS**).

$$MARKET = W_0 + W_1 \times DIS$$

МНОГОФАКТОРНАЯ

$$Y = W_0 + W_1 \times X_1 + \ldots + W_N \times X_N$$

КЕЙС

Модель, которая предсказывает объем двусторонней торговли между двумя странами (**MARKET**) на основе расстояния между столицами этих стран (**DIS**) и наличия общего языка (**LAN**)

$$MARKET = W_0 + W_1 \times DIS + W_N \times LAN$$

	country_x	country_y	MARKET	DIS	LAN	...	CNT_AGR
0	Russia	Belarus	56.7	675	yes	...	12
1	India	Russia	70.6	4340	no	...	9
...	...	...	...	...	...	...	...

ПОДБОР ПРЕДИКТОРОВ

КОРРЕЛЯЦИОННЫЙ АНАЛИЗ

- Выбираем предикторы (**X**) с самой сильной связью с целевой (**Y**)
- Между самими предикторами (**X**) стоит избегать очень сильной корреляции. Это может может привести к **мультиколлинеарности**. Если упрощать, эта такая ситуация, что предикторы слишком похожи и как бы дублируют друг друга.

КОЛИЧЕСТВО НАБЛЮДЕНИЙ

- Каждый предиктор должен быть обеспечен минимум 100 наблюдениями.

РАСПРЕДЕЛЕНИЕ ПРИЗНАКОВ

- Стоит выбирать количественные признаки, которые имеют симметричное куполообразное распределение (нормальное распределение).
- Если есть возможность, делать несимметричные распределения – симметричными.

ДЕЛЕНИЕ НА ТРЕНИРОВОЧНУЮ И ТЕСТОВУЮ

$$Y = W_0 + W_1 \times X_1 + W_2 \times X_2 + \ldots + W_N \times X_N$$

```
from sklearn.model_selection import train_test_split
X = датафрейм[['предиктор 1', 'предиктор 2', …]]
Y = датафрейм['целевая']
X_train, X_test, y_train, y_test = train_test_split(X, Y,
                                                    test_size=доля тестовой,
                                                    random_state=воспроизводимость)
```



ДЕЛЕНИЕ НА ТРЕНИРОВОЧНУЮ И ТЕСТОВУЮ. КЕЙС

$$MARKET = W_0 + W_1 \times DIS + W_2 \times LAN + \ldots + W_N \times CNT_AGR$$

```
from sklearn.model_selection import train_test_split
X = df[['DIS', 'LAN', …, 'CNT_AGR']]
Y = df['MARKET']
X_train, X_test, y_train, y_test = train_test_split(X, Y, test_size=0.2,
                                                    random_state=33)
```



ОБУЧЕНИЕ МОДЕЛИ

Обучение модели — это поиск параметров/коэффициентов модели (W_0, W_1, …, W_N)

- Линейная модель обучается с помощью метода наименьших квадратов (МНК)
- Обучение модели происходит на тренировочной выборке (`X_train`, `y_train`).

$$Y = W_0 + W_1 \times X_1 + W_2 \times X_2 + \ldots + W_N \times X_N$$

```
from sklearn.linear_model import LinearRegression
модель = LinearRegression().fit(X_train, y_train)
```

СВОБОДНЫЙ КОЭФФИЦИЕНТ (W_0)

```
модель.intercept_
```

КОЭФФИЦИЕНТЫ НЕЗАВИСИМЫХ ПЕРЕМЕННЫХ (W_1, …, W_N)

```
модель.coef_
```

ОБУЧЕНИЕ МОДЕЛИ. КЕЙС

$$MARKET = W_0 + W_1 \times DIS + W_2 \times LAN + \ldots + W_N \times CNT_AGR$$

```
from sklearn.linear_model import LinearRegression
model = LinearRegression().fit(X_train, y_train)
```

СВОБОДНЫЙ КОЭФФИЦИЕНТ (W_0)

```
model.intercept_
```

```
15
```

КОЭФФИЦИЕНТЫ НЕЗАВИСИМЫХ ПЕРЕМЕННЫХ (W_1, …, W_N)

```
model.coef_
```

```
array([-0.8, 0.7, …, 0.1])
```

$$MARKET = 15 - 0.8 \times DIS + 0.7 \times LAN + \ldots + 0.1 \times CNT_AGR$$

ОЦЕНКА КАЧЕСТВА МОДЕЛИ

```
from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error
y предсказанный = модель.predict(X тестовый)
метрика(y тестовый, y предсказанный)
```

КОЭФФИЦИЕНТ ДЕТЕРМИНАЦИИ

```
r2_score()
```

Описывает долю разброса данных целевой переменной

$$R^2 = 1 - \frac{\sum(y - \hat{y})^2}{\sum(y - \bar{y})^2}$$

- Принимает значения: от **0** до **1** (в редких случаях может быть отрицательным)
- Чем ближе к **1**, тем лучше

СРЕДНЕКВАДРАТИЧНАЯ ОШИБКА

```
mean_squared_error()
```

Описывает усредненный квадрат ошибки модели:

$$MSE = \frac{\sum(y - \hat{y})^2}{n}$$

- Принимает значения: от **0** до **+∞**
- Используется для сравнения моделей. Та модель лучше, у которой MSE меньше.

СРЕДНЯЯ АБСОЛЮТНАЯ ОШИБКА

```
mean_absolute_error()
```

Описывает усредненную ошибку модели:

$$MAE = \frac{\sum|y - \hat{y}|}{n}$$

- Принимает значения: от **0** до **+∞**
- Используется для сравнения моделей. Та модель лучше, у которой MAE меньше.

ОЦЕНКА КАЧЕСТВА МОДЕЛИ. КЕЙС

```
from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error
y_pred = model.predict(X_test)
```

$$MARKET = 15 - 0.8 \times DIS + 0.7 \times LAN + \ldots + 0.1 \times CNT_AGR$$

КОЭФФИЦИЕНТ ДЕТЕРМИНАЦИИ (R^2)

```
r2_score(y_test, y_pred)
```

```
0.75
```

СРЕДНЕКВАДРАТИЧНАЯ ОШИБКА (MSE)

```
mean_squared_error(y_test, y_pred)
```

```
5.63
```

СРЕДНЯЯ АБСОЛЮТНАЯ ОШИБКА (MAE)

```
mean_absolute_error(y_test, y_pred)
```

```
1.24
```

A7

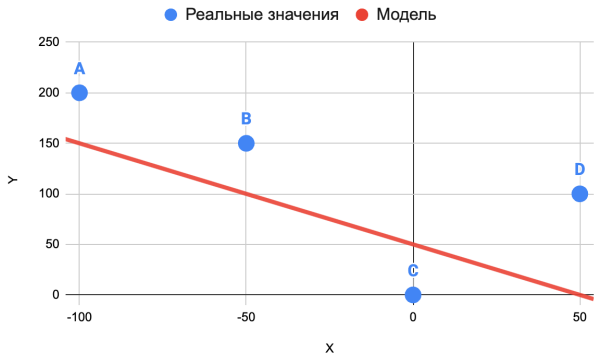
ДЕМО: После обучения линейной регрессии на выборке из 1000 наблюдений и 3 признаков для предсказания стоимости квартиры (в тысячах рублей) исследователь получил следующие метрики на тестовой выборке:

MAE = 2.5
MSE = 50.25
R^2 = 0.85

Какое из следующих утверждений наиболее корректно описывает ситуацию?

- Значение R^2 указывает на то, что модель достаточно хорошо описывает зависимость между признаками и стоимостью квартиры.
- В среднем модель ошибается на 50.25 тысяч рублей
- Разница между MSE и MAE говорит о том, что наша модель хорошего качества.
- Коэффициент детерминации R^2 показывает, что модель объясняет 15% дисперсии целевой переменной.

Вар 2: Была построена линейная модель по четырем наблюдениям, которая предсказывает, как некоторый признак X влияет на признак Y. На графике изображена получившаяся модель (красным) и реальные данные (синим). Укажите, **не**верное утверждение



- R^2 = 0.2
- MSE = 4375
- MAE = 62.50
- Значения метрик указывают на высокое качество построенной модели

ИНТЕРПРЕТАЦИЯ ПАРАМЕТРОВ (1)

$$Y = W_0 + W_1 \times X_1 - W_2 \times X_2 + W_3 \times LN(X_3) - W_4 \times LN(X_4)$$

СВОБОДНЫЙ КОЭФФИЦИЕНТ (W_0)

```
модель.intercept_
```

- если все предикторы равны 0, то **Y** равен w_0
- не всегда можно интерпретировать

КОЭФФИЦИЕНТЫ НЕЗАВИСИМЫХ ПЕРЕМЕННЫХ (W_1, …, W_N)

```
модель.coef_
```

- X_1 и X_2 количественные:
  - если X_1 ↑ на **n**, **Y** ↑ на $n*W_1$
  - если X_2 ↑ на **n**, **Y** ↓ на $n*W_2$

- X_1 и X_2 категориальные:
  - если X_1 равен **n**, **Y** ↑ на $n*W_1$
  - если X_2 равен **n**, **Y** ↓ на $n*W_2$

- X_3 и X_4 количественные:
  - если X_3 ↑ на 1%, **Y** ↑ на $\frac{W_3}{100}$
  - если X_4 ↑ на 1%, **Y** ↓ на $\frac{W_4}{100}$

ИНТЕРПРЕТАЦИЯ ПАРАМЕТРОВ (2)

$$LN(Y) = W_0 + W_1 \times X_1 - W_2 \times X_2 + W_3 \times LN(X_3) - W_4 \times LN(X_4)$$

СВОБОДНЫЙ КОЭФФИЦИЕНТ (W_0)

```
модель.intercept_
```

- если все предикторы равны 0, то **Y** равен e^{W_0}
- не всегда можно интерпретировать

КОЭФФИЦИЕНТЫ НЕЗАВИСИМЫХ ПЕРЕМЕННЫХ (W_1, …, W_N)

```
модель.coef_
```

- X_1 и X_2 количественные:
  - если X_1 ↑ на 1, **Y** ↑ на 100*W_1%
  - если X_2 ↑ на 1, **Y** ↓ на 100*W_2%

- X_1 и X_2 бинарные (1/0):
  - если X_1 равен 1, **Y** ↑ на 100*W_1%
  - если X_2 равен 1, **Y** ↓ на 100*W_2%

- X_3 и X_4 количественные:
  - если X_3 ↑ на 1%, **Y** ↑ на W_3%
  - если X_4 ↑ на 1%, **Y** ↓ на W_4%

ИНТЕРПРЕТАЦИЯ ПАРАМЕТРОВ. КЕЙС

КЕЙС

Исследователь построил четыре модели, которые предсказывают объем двусторонней торговли между двумя странами (**MARKET**, млрд. долларов) на основе количества торговых соглашений между странами (**CNT_AGR**). **Интерпретируйте параметры построенных моделей**.

$$MARKET = 10 + 0.1 \times CNT_AGR$$

$$LN(MARKET) = 10 + 0.15 \times CNT_AGR$$

$$MARKET = 10 + 13 \times LN(CNT_AGR)$$

$$LN(MARKET) = 10 + 2 \times LN(CNT_AGR)$$

A6

ДЕМО: Аналитик Иван построил модель для прогнозирования выручки компании в зависимости от количества сотрудников и затрат на рекламу:

$$REVENUE = 2.5 \times Employees + 10 \times \ln(AdSpent)$$

Выберите верное утверждение о влиянии признаков на выручку:

- При увеличении затрат на рекламу на 1% выручка уменьшается примерно на 0.1 миллиона долларов при неизменных значениях других факторов.
- При увеличении затрат на рекламу на 1 миллион долларов выручка увеличивается примерно на 10 миллионов долларов при неизменных значениях других факторов.
- При увеличении количества сотрудников на 1% выручка увеличивается примерно на 2.5 миллиона долларов при неизменных значениях других факторов.
- При увеличении количества сотрудников на одного человека выручка увеличивается в среднем на 2.5 миллиона долларов, при неизменных значениях других факторов.

ВАР 3: Исследователь Борис в течение 365 дней собирал данные о переменных Y, X и Z. После этого он оценил следующую линейную регрессию:

$$Y = 120 + X + 15Z$$

- При увеличении переменной X при прочих равных переменная Y не изменится.
- При увеличении переменной Z при прочих равных переменная Y уменьшится.
- При увеличении переменной Z при прочих равных переменная X также увеличится.
- При увеличении переменной Z при прочих равных переменная Y также увеличится.

ВАР 9: Исследователь Иван в течение 1000 дней собирал данные о переменных Y, X и Z. После этого он оценил следующую линейную регрессию:

$$Y = 90 + 0X + 0Z$$

- При увеличении переменной X при прочих равных переменная Y уменьшится.
- При увеличении переменной X при прочих равных переменная Y также увеличится.
- Переменные X и Z не коррелируют.
- Модель эквивалента регрессии на константу.

ИНТЕРПРЕТАЦИЯ W_1

ДОПОЛНИТЕЛЬНО. НЕ ДЛЯ НЭ, А ДЛЯ ИНТЕРЕСУЮЩИХСЯ

Прошлый интерпретации работают на малых w_n, в общем виде:

$Y = W_0 + W_1 \times X_1$

Если **X_1** увеличится на K, …

$Y = W_0 + W_1 \times (X_1 + K)$

$Y = W_0 + W_1 \times X_1 + \mathbf{W_1 \times K}$

… **Y** увеличится на **$W_1 \times K$**

$LN(Y) = W_0 + W_1 \times X_1$

$Y = e^{W_0 + W_1 \times X_1}$

$Y = e^{W_0} \times e^{W_1 \times X_1}$

Если **X_1** увеличится на K, …

$Y = e^{W_0} \times e^{W_1 \times (X_1 + K)}$

$Y = e^{W_0} \times e^{W_1 \times X_1 + W_1 \times K}$

$Y = e^{W_0} \times e^{W_1 \times X_1} \times \mathbf{e^{W_1 \times K}}$

… **Y** увеличится в **$e^{W_1 \times K}$** раз

$Y = W_0 + W_1 \times LN(X_1)$

Если **X_1** увеличится в K раз, …

$Y = W_0 + W_1 \times LN(X_1 \times K)$

$Y = W_0 + W_1 \times LN(X_1) + \mathbf{W_1 \times LN(K)}$

… **Y** увеличится на **$W_1 \times LN(K)$**

$LN(Y) = W_0 + W_1 \times LN(X_1)$

$Y = e^{W_0 + W_1 \times LN(X_1)}$

$Y = e^{W_0} \times e^{W_1 \times LN(X_1)}$

Если **X_1** увеличится в K раз, …

$Y = e^{W_0} \times e^{W_1 \times LN(X_1 \times K)}$

$Y = e^{W_0} \times e^{W_1 \times LN(X_1) + W_1 \times LN(K)}$

$Y = e^{W_0} \times e^{W_1 \times LN(X_1)} \times e^{W_1 \times LN(K)}$

$Y = e^{W_0} \times e^{W_1 \times LN(X_1)} \times \mathbf{K^{W_1}}$

… **Y** увеличится в **K^{W_1}** раз

ПРЕДСКАЗАНИЕ ЦЕЛЕВОЙ ПЕРЕМЕННОЙ. КЕЙС

КЕЙС

Исследователь построил девять моделей, которые предсказывают объем двусторонней торговли между двумя странами (**MARKET**, млрд. долларов) на основе количества торговых соглашений между странами (**CNT_AGR**). Известно, что количество торговых соглашений (**CNT_AGR**) между: Россией и Палау равно 0; Россией и Турцией равно 5. Укажите чему согласно модели будет равен объем торговли (**MARKET**) между этими странами в каждой модели:

```
model.predict([[0]])   #Россия-Палау
```

```
???
```

MARKET = 10 + 0.1 × CNT_AGR

MARKET = 10 + 13× LN(**CNT_AGR**)

MARKET = 10 + 2 × LN(**CNT_AGR** + 1)

LN(**MARKET**) **= 10 + 0.15 × CNT_AGR**

LN(**MARKET** + 1) **= 10 + 0.15 × CNT_AGR**

```
model.predict([[5]]) #Россия-Турция
```

```
???
```

LN(**MARKET**) **= 10 + 0.15 ×** LN(**CNT_AGR**)

LN(**MARKET** + 1) **= 10 + 0.15 ×** LN(**CNT_AGR**)

LN(**MARKET**) **= 10 + 0.15 ×** LN(**CNT_AGR** + 1)

LN(**MARKET** + 1) **= 10 + 0.15 ×** LN(**CNT_AGR** + 1)