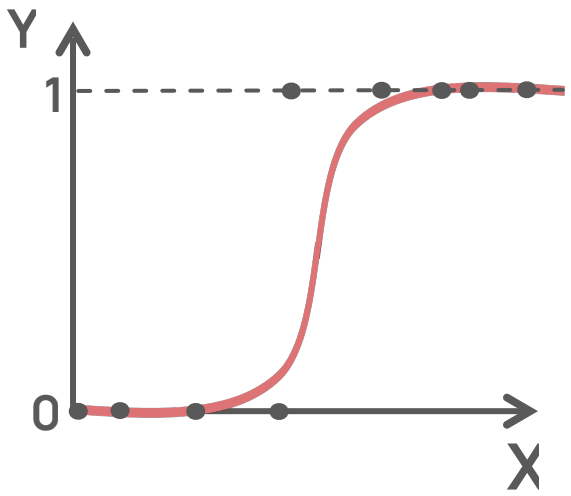
ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

Логистическая регрессия — это метод анализа данных, предназначенный для моделирования зависимости между одной или несколькими независимыми переменными (предикторами) и **категориальной** зависимой переменной (целевым признаком).

$$P(Y=1) = \frac{1}{1 + e^{-(W_0 + W_1 \times X_1)}}$$

$$P(Y=1) = \sigma(W_0 + W_1 \times X_1)$$



КЕЙС: КАК БУДЕТ ВЫГЛЯДИТ РЕГРЕССИЯ?

Исследователь строит модель, которая предсказывает, будет ли международный договор ратифицирован (**rat**) национальным парламентом страны-участницы на основе значения общественной поддержки (**sup**).

	country	rat	sup
0	Japan	1	0.75
1	France	0	0.45
...	...	..	...

ВИДЫ ЛОГИСТИЧЕСКИХ РЕГРЕССИЙ

ПО КОЛИЧЕСТВУ ПРЕДИКТОРОВ

ОДНОФАКТОРАЯ

$$P(Y = 1) = \sigma(W_0 + W_1 \times X_1)$$

МНОГОФАКТОРАЯ

$$P(Y = 1) = \sigma(W_0 + W_1 \times X_1 + \ldots + W_N \times X_N)$$

ПО ТИПУ ЦЕЛЕВОЙ ПЕРЕМЕННОЙ

Y – БИНАРНЫЙ (0/1)

- Задача бинарной классификации
- Вероятность попадания в положительный класс (1)

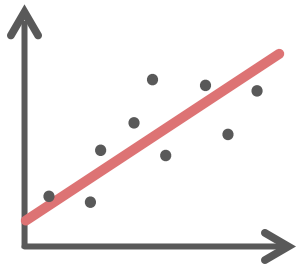
Y – КАТЕГОРИАЛЬНЫЙ НЕ БИНАРНЫЙ

- Задача мульти классовой классификации
- Вероятность попадания в каждый из классов

СРАВНЕНИЕ ЛИНЕЙНОЙ И ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

ЛИНЕЙНАЯ РЕГРЕССИЯ

$$Y = W_0 + W_1 \times X_1$$



Целевая (**Y**): количественная

Пример: зарплата

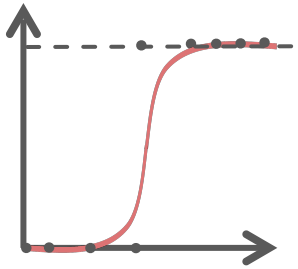
Обучение модели: метод наименьших квадратов (МНК)

Результат: непрерванная количественная

Пример: зарплата ($150.55, $230.23, ...)

ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

$$P(Y=1) = \sigma(W_0 + W_1 \times X_1)$$



Целевая (**Y**): бинарная

Пример: объявление банкротства (1/0)

Обучение модели: метод максимального правдоподобия

Результат: вероятность попадания в положительный класс (1)

Пример: вероятность банкротства (0.55, 0.39, ...)

ПРОВЕРИМ СЕБЯ

Сопоставьте описание модели и её вид:

	ОПИСАНИЕ
1	Влияние торговой зависимости и уровня демократии на факт введения санкций против страны.
2	Влияние расходов на оборону на объем экспорта вооружений
3	Прогнозирование, подаст ли страна заявку на вступление в Европейский союз
4	Предсказание индекса восприятия коррупции на основе ВВП и уровня демократии.
5	Влияние торговой зависимости на вероятность введения санкций.
6	Предсказание внешнеполитического курса страны на основе доли торговли с ЕС и индекса идеологической близости с США

	МОДЕЛЬ
A	Линейная однофакторная
B	Линейная многофакторная
C	Логистическая однофакторная модель бинарной классификации
D	Логистическая многофакторная модель бинарной классификации
E	Логистическая однофакторная модель мульти классовой классификации
F	Логистическая многофакторная модель мульти классовой классификации

КЕЙС

КЕЙС

Исследователь хочет построить модель, которая предсказывает вероятность того, будет ли страной ратифицирован международный договор (**rat**) в зависимости от различных факторов.

$$P(\text{RAT} = 1) = \sigma(W_0 + W_1 \times \text{GDP} + W_2 \times \text{EXP_OIL} + \ldots)$$

country – название страны
GDP – ВВП
EXP_OIL – объем экспорта нефти
DEM – индекс демократии
...
RAT – ратифицирован ли международный договор

	country	GDP	EXP_OIL	DEM	...	RAT
0	Germany	48000	2.1	8.68	...	1
1	India	2000	12.5	6.61	...	1
2	Russia	11000	60.3	3.31	...	0
...	...	...	...	...	...	...

Как подбирать предикторы в модель?

ДЕЛЕНИЕ ВЫБОРКИ НА ТРЕНИРОВОЧНУЮ И ТЕСТОВУЮ

$$P(\text{RAT} = 1) = \sigma(W_0 + W_1 \times \text{GDP} + W_2 \times \text{EXP_OIL} + \ldots)$$

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X,
                                                    Y,
                                                    test_size=0.2,
                                                    random_state=42)
```

Зачем нужно делить выборку на обучающую и тестовую?

Для какие этапов работы с моделью нужна тренировочная выборка, а для каких тестовая?

За что отвечает параметр `random_state` в функции?

ОБУЧЕНИЕ МОДЕЛИ

Модель логистической регрессии обучается с помощью **метода максимального правдоподобия**:

```
from sklearn.linear_model import LogisticRegression
модель = LogisticRegression().fit(X тренировочный, y тренировочный)
```

$$P(\text{RAT} = 1) = \sigma(W_0 + W_1 \times \text{GDP} + W_2 \times \text{EXP_OIL} + \ldots)$$

```
from sklearn.linear_model import LogisticRegression
model = LogisticRegression().fit(X_train, y_train)
```

Что значит обучить модель?

ПРЕДСКАЗАНИЯ МОДЕЛИ

ПРЕДСКАЗАНИЕ ВЕРОЯТНОСТИ

```
модель predict_proba([[значение 1, …]])
```

ПРЕДСКАЗАНИЕ КЛАССА

```
модель.predict([[значение 1, …]])
```

$$P(RAT = 1) = \sigma(W_0 + W_1 \times GDP + W_2 \times EXP_OIL + \ldots)$$

```
model.predict_proba(X_test)
```

```
array([[0.99135784, 0.00864216],
       [0.56830895, 0.43169105],
       [0.17511809, 0.82488191],
       …
      ])
```

```
model.predict(X_test)
```

```
array([0,
       0,
       1,
       …
      ])
```

МЕТРИКА LOG LOSS

```
from sklearn.metrics import log_loss
log_loss(y тестовое, предсказанная вероятность*)
```

Log loss – эта мера показывает степень соответствия прогнозируемых моделью вероятностей истинным значениям классов. Является аналогом MSE, но для логистической регрессии

- Меняется в диапазоне от 0 до +∞
- Чем меньше, тем лучше качество
- Используется для сравнения моделей между собой.

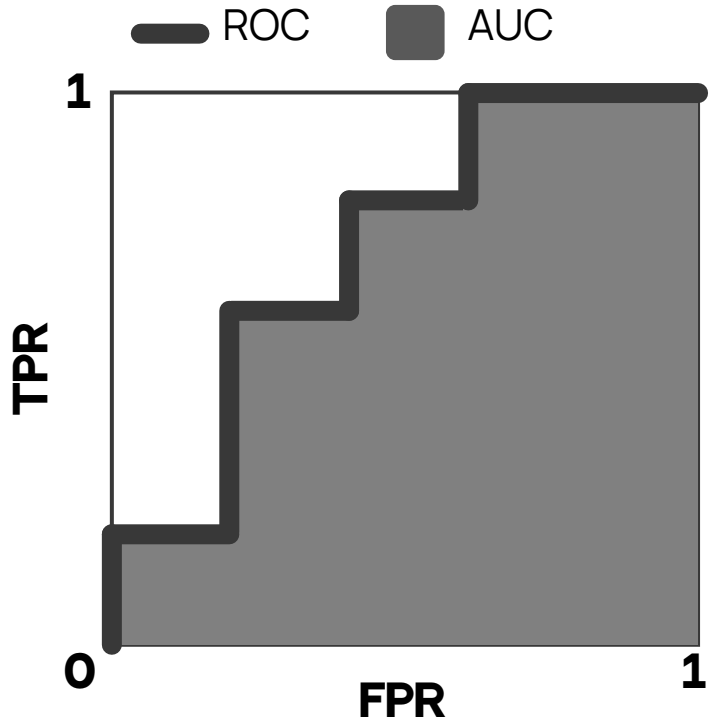
```
from sklearn.metrics import log_loss
y_pred_prob = model.predict_proba(X_test)
log_loss(y_test, y_pred_prob)
```

```
0.123
```

```
*модель.predict_proba(X тестовое)
```

МЕТРИКА ROC-AUC

```
import matplotlib.pyplot as plt
from sklearn.metrics import roc_curve, roc_auc_score
```



ROC-КРИВАЯ — зависимость **TPR** (доля правильно предсказанных положительных примеров) от **FPR** (доля неправильно предсказанных отрицательных примеров):

```
fpr, tpr, th = roc_curve(y тест,
                         вероятность класса 1*)
plt.plot(fpr, tpr)
```

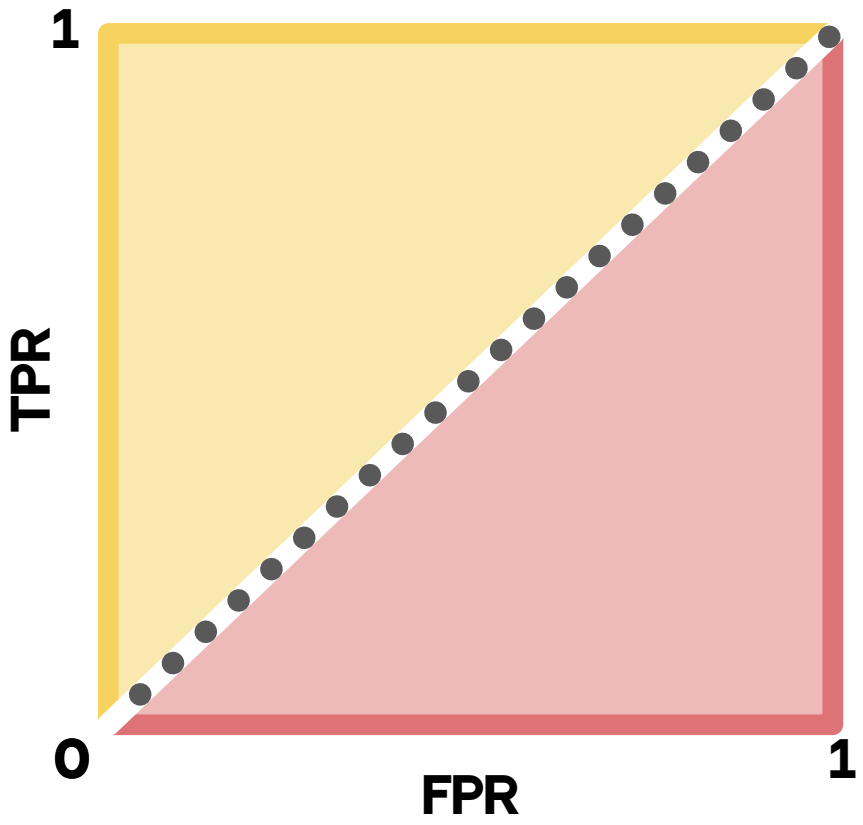
AUC — площадь под ROC-кривой. Меняется в диапазоне от 0 до 1:

```
roc_auc_score(y тест, вероятность класса 1*)
```

```
*модель.predict_proba(X тестовое)[:, 1]
```

ROC-AUC. ИНТЕРПРЕТАЦИЯ (1)

СТАТИСТИКА



- **AUC = 1**

  Идеальный классификатор

- **AUC = 0.5**

  Случайный классификатор

- **AUC = 0**

  Наихудший классификатор

- **0.5 < AUC < 1**

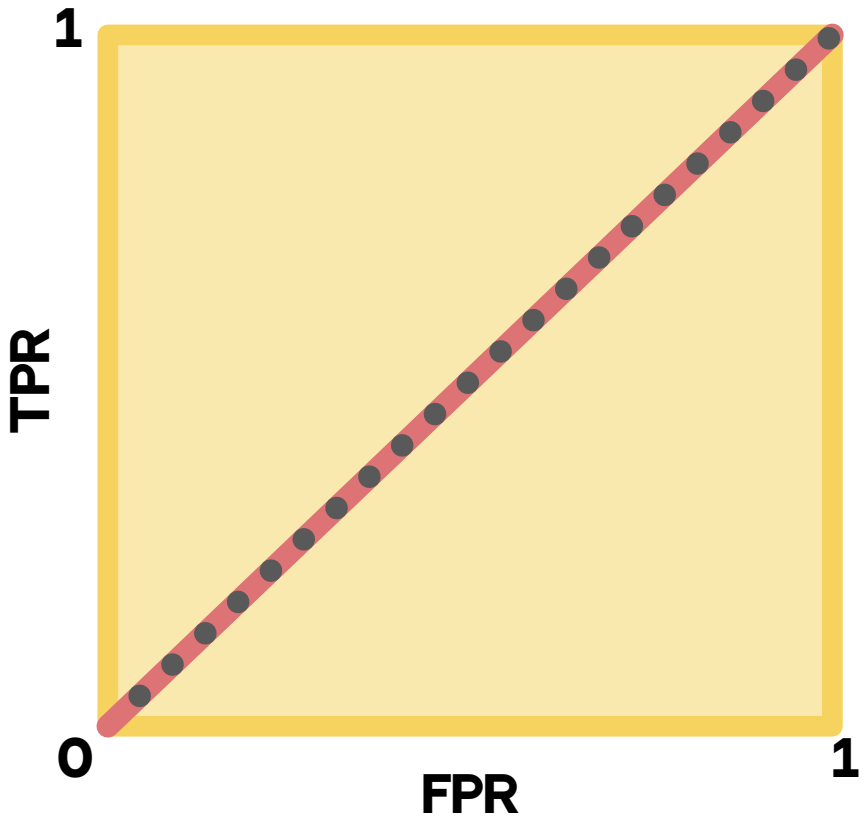
  Логистическая регрессия **лучше** случайного классификатора

- **0 < AUC < 0.5**

  Логистическая регрессия **хуже** случайного классификатора

ROC-AUC. ИНТЕРПРЕТАЦИЯ (2)

МАШИННОЕ ОБУЧЕНИЕ



- **AUC = 0** или **AUC = 1**

  Идеальный классификатор

- **AUC = 0.5**

  Наихудший классификатор
  Случайный классификатор

- **0 < AUC < 0.5** или **0.5 < AUC < 1**

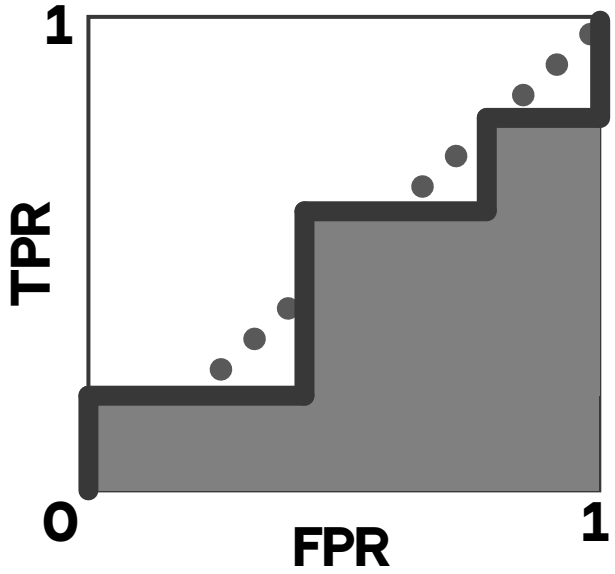
Логистическая регрессия **лучше** случайного классификатора

ROC-AUC. КЕЙС

```
import matplotlib.pyplot as plt
from sklearn.metrics import roc_curve, roc_auc_score
y_pred_proba_1 = model.predict_proba(X_test)[:, 1]
```

ROC КРИВАЯ

```
fpr, tpr, th = roc_curve(y_test, y_pred_proba_1)
plt.plot(fpr, tpr)
```



AUC

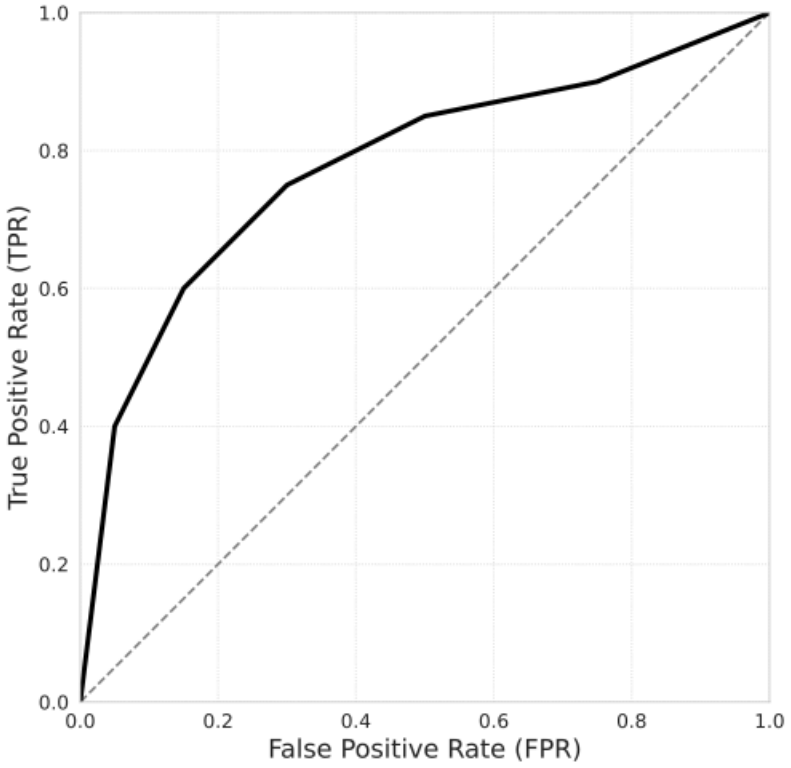
```
roc_auc_score(y_test, y_pred_class)
```

```
0.62
```

ROC AUC — это метрика качества бинарной классификации, показывающая способность классификатора различать положительные и отрицательные классы объектов.

A8_ДЕМО

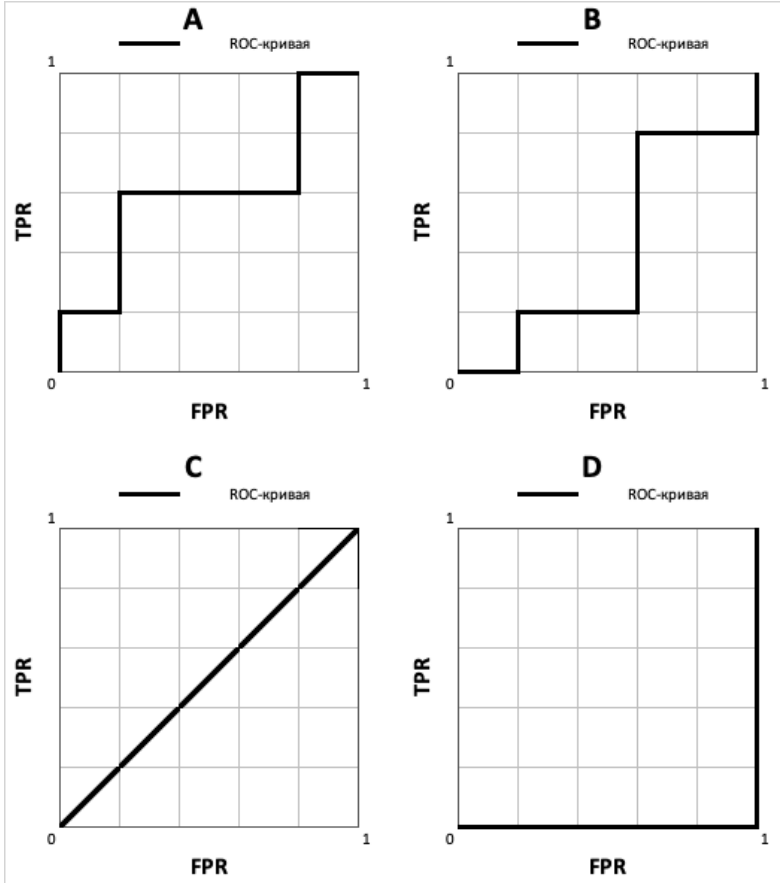
ДЕМО: На рисунке изображена ROC-кривая для некоторой логистической регрессии, построенная для тестовой выборки. Выберите все верные утверждения о качестве предсказаний этой регрессии. Примечание: При решении задачи используйте подход машинного обучения.



- Если FPR = 0.5, то TPR модели примерно 0.6.
- ROC-AUC данной модели приблизительно равен 0.5.
- Изображенная ROC-кривая совпадает с кривой идеального классификатора.
- В среднем логистическая регрессия предсказывает лучше, чем случайный классификатор.

A8_1

Вар 1: Укажите, какая из логистических моделей демонстрирует качество классификации выше, чем случайный классификатор.
Примечание: При решении задачи используйте статистический подход.



МАТРИЦА ОШИБОК

```
from sklearn.metrics import confusion_matrix
confusion_matrix(y тестовое,  предсказанные классы*)
```




```
*модель.predict(X тестовое)
```

TN (True Negative) — количество наблюдений из негативного класса, которые модель тоже классифицировала как негативные

TP (True Positive) — количество наблюдений из положительного класса, которые модель тоже классифицировала как положительные

FP (False Positive) — количество наблюдений из негативного класса, которые модель классифицировала как положительный

FN (False Negative) — количество наблюдений из положительного класса, которые модель классифицировала как негативный

МАТРИЦА ОШИБОК. КЕЙС

```
from sklearn.metrics
y_pred_class = model.predict(X_test)
confusion_matrix(y_test, y_pred_class)
```



- **???** стран **не ратифицировали** соглашение о климате и модель их правильно идентифицировала
- **???** стран **ратифицировали** соглашение о климате и модель их правильно идентифицировала
- **???** стран **не ратифицировали** соглашение о климате, но модель их определила как **ратифицировавших**
- **???** стран **ратифицировали** соглашение о климате, но модель их определила как **не ратифицировавших**

A8_2

Вар 2: Была разработана модель для прогнозирования банкротства компаний, где целевая переменная определяется следующим образом:

- Y=1 — компания становится банкротом;
- Y=0 — компания продолжает стабильно функционировать.

Полученная матрица ошибок модели представлена ниже:

		Настоящий	
		класс 0	**класс 1**
Предсказанный	**класс 0**	50	20
	класс 1	100	20

- Из всех компаний, которые действительно объявили себя банкротами, ваша модель смогла верно идентифицировать меньше половины.
- Модель работает хуже, чем случайный классификатор
- Из всех компаний, которые модель объявила банкротами, действительно оказались банкротами около 80%
- ROC-кривая модели совпадает со случайным классификатором

A8_3

Вар 3: Аналитиком в инвестиционном банке были разработаны четыре модели для прогнозирования банкротства компаний. Целевая переменная модели определяется следующим образом:

- Y=1 — компания становится банкротом;
- Y=0 — компания продолжает стабильно функционировать.

Укажите, какую модель следует использовать аналитику, если основное требование — обеспечить минимальный процент пропусков настоящих банкротств среди всех имеющихся случаев возможного дефолта.

Для каждой из моделей были построены матрицы ошибок:

A

		МОДЕЛЬ 0	МОДЕЛЬ 1
ФАКТ	0	140	60
	1	90	110

B

		МОДЕЛЬ 0	МОДЕЛЬ 1
ФАКТ	0	130	70
	1	80	120

C

		МОДЕЛЬ 0	МОДЕЛЬ 1
ФАКТ	0	120	80
	1	70	130

D

		МОДЕЛЬ 0	МОДЕЛЬ 1
ФАКТ	0	110	90
	1	60	140

МЕТРИКИ КЛАССИФИКАЦИИ

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
метрика(y тестовое,  предсказанные классы*)
```

ACCURACY

Доля правильно определенных объектов

$$\frac{TN + TP}{TN + TP + FP + TP}$$

PRECISION

Доля правильно определенных объектов положительного класса (**TP**), среди всех предсказанных положительных примеров (**TP** и **FP**):

$$\frac{TP}{TP + FP}$$

RECALL

Доля правильно определенных объектов положительного класса (**TP**), среди всех положительных примеров (**TP** и **FN**):

$$\frac{TP}{TP + FN}$$

F1

Среднее гармоническое **Precision** и **Recall**:

$$\frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}}$$

ФАКТ \ ПРЕДСКАЗАНИЕ	0	1
0	TN	FP
1	FN	TP

МЕТРИКИ КЛАССИФИКАЦИИ. КЕЙС

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
y_pred_class = model.predict(X_test)
```

ACCURACY

Доля правильно определенных стран:

```
accuracy_score(y_test, y_pred_class)
```

```
0.769230
```

PRECISION

Доля правильно определенных стран, ратифицировавших соглашение (**TP**), среди всех стран, которые модель определила как ратифицировавших (**TP** и **FP**):

```
precision_score(y_test, y_pred_class)
```

```
0.30769
```

RECALL

Доля правильно определенных стран, ратифицировавших соглашение (**TP**), среди всех стран, которые на самом деле его ратифицировали (**TP** и **FN**):

```
precision_score(y_test, y_pred_class)
```

```
0.435897
```

F1

Среднее гармоническое **Precision** и **Recall**:

```
f1_score(y_test, y_pred_class)
```

```
0.36373
```

A8_4_5

Вар 4:После обучения логистической регрессии для прогнозирования вероятности победы кандидата на выборах, исследователь получил следующие метрики на тестовой выборке:

log loss = 0.67
ROC-AUC = 0.78
Accuracy = 0.70

Укажите верное утверждение о модели:

- Модель правильно классифицировала 30% кандидатов
- Модель правильно классифицировала 78% кандидатов
- Модель правильно классифицировала 67% кандидатов
- Модель правильно классифицировала 70% кандидатов

Вар 5:После обучения логистической регрессии для прогнозирования вероятности победы кандидата на выборах, исследователь получил следующие метрики на тестовой выборке:

Accuracy = 1
Precision = 1
Recall = 1

Укажите **не**верное утверждение о модели.

- log loss модели будет равно 0
- Значение F1 модели будет равно 1
- Скорее всего, модель переобучилась
- Значение ROC-AUC модели будет равно 0

ПАРАМЕТРЫ РЕГРЕССИИ

$$P(\text{RAT} = 1) = \sigma(W_0 + W_1 \times \text{GDP} + W_2 \times \text{EXP_OIL} + \ldots)$$

СВОБОДНЫЙ КОЭФФИЦИЕНТ

```
model.intercept_
```

```
array([0.234567])
```

КОЭФФИЦИЕНТЫ НЕЗАВИСИМЫХ ПЕРЕМЕННЫХ

```
model.coef_
```

```
array([[0.2578821, -0.01750214, …]])
```

$$P(\text{RAT} = 1) = \sigma(0.23 + 0.26 \times \text{GDP} - 0.02 \times \text{EXP_OIL} + \ldots)$$